

Optimisation sous contraintes

Soit le problème d'optimisation

$$(P) : \min f(x)$$

s.c.

$$h_i(x) \leq 0$$

$$g_i(x) \geq 0$$

$$m_i(x) = 0$$

Lagrangien ou fonction de Lagrange
associé à ce problème

$$L(x, \alpha, \theta, \lambda) = f(x) - \sum_i \lambda_i h_i(x) - \sum_i \alpha_i g_i(x) - \sum_i \theta_i m_i(x)$$

$\lambda_i (\in \mathbb{R}_+)$ positif, α_i négatif et $\theta_i \in \mathbb{R}$
pour tout i

- Deux conditions à vérifier pour résoudre ce problème, lesquelles conditions sont similaires à

→ La dérivée de f est nulle

($f'(x) = 0$ permet de trouver l'extremum)

→ $L''(x) > 0$ permet de prouver que cet extremum est un minimum.

Condition du 1^{er} ordre

$$\nabla L(x, \lambda, \alpha, \theta) = 0 \quad (\nabla L(x_i) = \left(\frac{\partial L}{\partial x_i} \right))$$

permet de déterminer $x^*, \lambda^*, \alpha^*, \theta^*$

Condition du 2nd ordre

$$H \succ 0,$$

La matrice hessienne de L est demi-définie positive, i.e.

$$(v^T H L v \geq 0 \text{ pour tout vecteur } v \text{ non nul})$$

Exemple 1 : Calcul du gradient d'une fonction

$$g((x,y), \lambda) = x^3 + y - \lambda(1 - x^2 - 2y^2)$$

Solution:

$$\nabla g((x,y), \lambda) = \left(\frac{\partial g}{\partial x}, \frac{\partial g}{\partial y}, \frac{\partial g}{\partial \lambda} \right)$$

est le vecteur constitué des dérivées premières de g par rapport à chacune de ses composantes (x, y et λ).

$$\frac{\partial g}{\partial x} = 3x^2 + 2\lambda x; \quad \frac{\partial g}{\partial y} = 1 + 4\lambda y.$$

$$\frac{\partial g}{\partial \lambda} = x^2 + 2y^2 - 1.$$

Exemple 2 : Calcul de la matrice Hessianne d'une fonction

Calculons la matrice hessienne de g .

$$H_g = \begin{bmatrix} \frac{\partial^2 g}{\partial x^2} & \frac{\partial^2 g}{\partial x \partial y} & \frac{\partial^2 g}{\partial x \partial \lambda} \\ \frac{\partial^2 g}{\partial y \partial x} & \frac{\partial^2 g}{\partial y^2} & \frac{\partial^2 g}{\partial y \partial \lambda} \\ -\frac{\partial^2 g}{\partial \lambda \partial x} & \frac{\partial^2 g}{\partial \lambda \partial y} & \frac{\partial^2 g}{\partial \lambda^2} \end{bmatrix}$$

$$\frac{\partial^2 g}{\partial x^2} = \frac{\partial}{\partial x} \left(\frac{\partial g}{\partial x} \right) = 6x + 2\lambda.$$

De même,

$$\frac{\partial^2 g}{\partial y^2} = 4\lambda ; \quad \frac{\partial^2 g}{\partial \lambda^2} = 0 ;$$

$$\frac{\partial^2 g}{\partial x \partial y} = \frac{\partial^2 g}{\partial y \partial x} = 0 ; \quad \frac{\partial^2 g}{\partial x \partial \lambda} = \frac{\partial^2 g}{\partial \lambda \partial x} = 2x$$

$$\frac{\partial^2 g}{\partial y \partial \lambda} = \frac{\partial^2 g}{\partial \lambda \partial y} = 4y.$$

$$H_g = \begin{bmatrix} 6x + 2\lambda & 0 & 2x \\ 0 & 4\lambda & 4y \\ 2x & 4y & 0 \end{bmatrix}$$

Remarque : La matrice Hessianne de toute fonction est une matrice symétrique.

Exemple 3: Lagrangien d'un problème d'optimisation avec contraintes.

Considérons le problème de minimisation

$$(P) : \min J(x, y) := x^3 + y$$

$$\text{s.c. } x^2 + 2y^2 - 1 = 0, x \geq 0$$

Le lagrangien de cette fonction est :

$$L(x, y, \lambda) = x^3 + y - \lambda(x^2 + 2y^2 - 1), \lambda \in \mathbb{R}.$$

Exemple 4: Résoudre le problème d'optimisation de l'exemple 3.

solution:

→ Condition de 1^{er} ordre :

$$\nabla L(x, y, \lambda) = 0 \Leftrightarrow \begin{cases} 3x^2 + 2\lambda x = 0 \\ 1 + 4\lambda y = 0 \\ x^2 + 2y^2 - 1 = 0 \end{cases}$$

$$\Leftrightarrow \begin{cases} x(3x + 2\lambda) = 0 \\ 1 + 4\lambda y = 0 \\ x^2 + 2y^2 = 1 \end{cases}$$

Il en résulte $\begin{cases} x^* = -2\lambda/3, 0 \end{cases}$ (cas $x > 0$)

$$y^* = -1/4\lambda$$

$$\lambda \in \mathbb{R}_- (\lambda \leq 0) \text{ car } x \geq 0.$$

→ Condition de 2nd ordre.

Il s'agit juste de vérifier que si

$$H_f(x^*, y^*, \lambda^*) \geq 0$$

pour conclure que (x^*, y^*) est une solution à ce problème.

Exemple 5 Comment montrer qu'une matrice est semi-définie positive ou non?

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$$

Soit $v \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} \in \mathbb{R}^2 \setminus \{(0,0)\}$

$$v^T A v = (v_1 \ v_2) \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$$

$$= 2v_1^2 + v_2^2 \geq 0$$

Donc $A \geq 0$ (semi-définie positive)

Application: Estimation des paramètres d'un modèle de régression linéaire sous contraintes.

On veut estimer par la méthode des moindres carrés ordinaires le paramètre β du modèle de régression

$$Y = X\beta + \epsilon,$$

sous la contrainte $R\beta = 0$

Ça revient à minimiser la somme des carrés résiduels réduits sous cette même contrainte. D'où le problème d'optimisation

$$\min \sum_i \varepsilon_i^2 \Leftrightarrow \min \| \varepsilon \|^2$$

s.c. $R\beta = c$ s.c. $R\beta = c$

$$\Leftrightarrow \min_{\beta} \| Y - X\beta \|^2$$

s.c. $R\beta = c = 0$

Le lagrangien de ce problème est donné par :

$$L(\beta, \lambda) = \| Y - X\beta \|^2 - \lambda(R\beta - c)$$

→ Condition de 1^{er} ordre, $\nabla L(\beta, \lambda) = 0$

$$\nabla L(\beta, \lambda) = \left(\frac{\partial L}{\partial \beta}, \frac{\partial L}{\partial \lambda} \right).$$

$$\begin{aligned} \frac{\partial L}{\partial \beta} &= -2X^T(Y - X\beta) - \lambda R \\ &= -2X^TY + 2X^TX\beta - \lambda R. \end{aligned}$$

$$\frac{\partial L}{\partial \lambda} = -(R\beta - c).$$

$$\nabla L(\beta, \lambda) = 0 \Leftrightarrow \begin{cases} -2X^TY + 2X^TX\hat{\beta}_c - \lambda R = 0 & (1) \\ R\hat{\beta}_c - c = 0 & (2) \end{cases}$$

Multiplier (1) par $R(x^T x)^{-1}$ et obtenir

$$-\alpha R(x^T x)^{-1} x^T Y + 2R(x^T x)^{-1} \underbrace{x^T x}_{I_p} \hat{\beta}_c - R(x^T x)^{-1} R^T \hat{\lambda} = 0$$

$$-\alpha R(x^T x)^{-1} x^T Y + 2R\hat{\beta}_c - R(x^T x)^{-1} R^T \hat{\lambda} = 0$$

(car $(x^T x)^{-1} (x^T x) = I_p$)

$$-\alpha R(x^T x)^{-1} x^T Y + 2c - R(x^T x)^{-1} R^T \hat{\lambda} = 0$$

$$(\text{car } R\hat{\beta}_c = c \text{ d'après (2)})$$

Nous obtenons alors pour $\hat{\lambda}$

$$\hat{\lambda} = \frac{1}{\alpha} [R(x^T x)^{-1} R^T]^{-1} [c - R(x^T x)^{-1} x^T Y]$$

Répliquons ensuite $\hat{\lambda}$ dans la 1^{re} équation :

$$-2x^T Y + 2x^T \hat{\beta}_c - 2R^T [R(x^T x)^{-1} R^T]^{-1} [c - R(x^T x)^{-1} x^T Y] = 0$$

D'où

$$\hat{\beta}_c = (x^T x)^{-1} x^T Y + (x^T x)^{-1} R^T [R(x^T x)^{-1} R^T]^{-1} (c - R\hat{\beta})$$

$$\boxed{\hat{\beta}_c = \hat{\beta}_{MCD} + (x^T x)^{-1} R^T [R(x^T x)^{-1} R^T]^{-1} (c - R\hat{\beta}).}$$

N.B. : La fonction $\|Y - x\beta\|^2$ étant convexe, $\hat{\beta}_c$ est l'unique solution du problème d'optimisation. Nous n'avons donc plus besoin de vérifier la condition de 2nd ordre.

Exemple: Un expérimentateur aimerait représenter le modèle

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

par la méthode des moindres carrés ordinaires,
sous la contrainte $\beta_1 = 1$.

Pourrait-il le faire par le modèle

$$\tilde{Y} - X_1 = \beta_0 + \beta_2 X_2 + \varepsilon ?$$

Solution: Oui

Il pourrait procéder comme suit :

• Poser $\tilde{Y} = Y - X_1$. Alors

$$\bullet \quad \tilde{Y} = \beta_0 + \beta_2 X_2 + \varepsilon.$$

• Estimer $\hat{\beta}$ par MCO et obtenir

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_2 \end{pmatrix}$$

• La solution est : $\hat{\beta}_c = \begin{pmatrix} \hat{\beta}_0 \\ 1 \\ \hat{\beta}_2 \end{pmatrix}$

Autre méthode: Utilisant le résultat précédent,
on pourra remarquer que pour

$$R = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 0 \\ -1 & 0 & 0 \end{bmatrix} \quad \text{et} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} \quad \text{et} \quad c = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$$

$$R\beta = c \Leftrightarrow \beta_1 = 1.$$

La solution $\hat{\beta}_c$ est donc

$$\hat{\beta}_c = \hat{\beta} + (x^T x)^{-1} D^T [D (x^T x)^{-1} D^T]^{-1} (c - D \hat{\beta})$$

où $\hat{\beta}$ est le paramètre estimé de β par la méthode des moindres carrés ordinaires
Sans aucune contrainte :

Partie 2: « Dummy Variables »

Ces variables interviennent lorsqu'on veut représenter par un modèle des données provenant de plusieurs groupes.

Illustration: 2 groupes

Groupe 1

$$\begin{array}{l} i \\ 1 \\ 2 \\ 3 \end{array} \quad \begin{array}{ll} y_i & x_{i1} \\ y_1 & x_{11} \\ y_2 & x_{12} \\ y_3 & x_{13} \end{array}$$

Groupe 2.

$$\begin{array}{ll} y'_1 & x'_{11} \\ y'_1 & x'_{12} \\ y'_2 & x'_{22} \\ y'_3 & x'_{33} \end{array}$$

Afin de représenter ces données par un modèle de régression, on fera intervenir la variable "dummy" qui code 1 si on est dans le groupe 1 et 0 sinon (ou inversement).

On a donc :

$$Y = X\beta + \varepsilon.$$

où

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdash \\ y'_1 \\ y'_2 \\ \vdash \\ y'_3 \end{bmatrix} \quad X = \begin{bmatrix} 1 & x_{11} & z \\ 1 & x_{12} & 1 \\ 1 & x_{13} & 1 \\ \hline 1 & x_{11} & 0 \\ 1 & x_{12} & 0 \\ 1 & x_{13} & 0 \end{bmatrix} \quad \left. \begin{array}{c} \text{Groupe 1} \\ \text{Groupe 2} \end{array} \right\}$$

En pratique, la matrice de design X contient aussi une variable d'interaction entre x et z ("dummy variable")

N.B.: p-groupes donnent lieu à p-1 "dummy variable"

Exemple:

Groupe A

X	Y
8	5.3
0	0.9
12	7.1
2	2.4

Groupe B

X	Y
9	5.1
7	4.4
8	5.2
6	3.8

Soit la variable "dummy"

$$Z = \begin{cases} 0 & \text{si groupe A} \\ 1 & \text{sinon.} \end{cases}$$

Alors

$$Y = \beta_0 + \beta_1 X + \alpha_0 Z + \alpha_1 \underbrace{XZ}_{\text{Interaction entre } X \text{ et } Z} + \epsilon$$

Interaction entre X et Z

$$\approx Y^T = (5.3, 0.9, 7.1, 2.4, 5.1, 4.4, 5.2, 3.8)$$

$$X = (8, 0, 12, 2, 9, 7, 8, 6)$$

$$Z = (0, 0, 0, 0, 1, 1, 1, 1)$$

$$T := XZ = (0, 0, 0, 0, 1, 9, 7, 8, 6)$$

$$Y = \beta_0 + \beta_1 X + \alpha_0 Z + \alpha_1 T + \epsilon$$

L'implémenter dans R et obtenir

$$(\hat{\beta}_0, \hat{\beta}_1, \hat{\alpha}_0, \hat{\alpha}_1) = (1.142, 0.506, -0.0418, -0.0360)$$

On pourrait effectuer des tests de significativité des variables Z et $T := XZ$ i.e.

$$H_0: \alpha_0 = \alpha_1 = 0 \quad \text{et} \quad H_a: \alpha_0 \neq 0 \text{ ou } \alpha_1 \neq 0$$

Le modèle sans Z et T est :

$$\hat{Y} = 1.075 + 0.492X$$

Statistique de Fisher (pour comparer les 2 modèles)

$$1^{\text{er}} \text{ modèle: } \hat{Y} = 1.142 + 0.506X - 0.0418Z - 0.036XT$$

$$2^{\text{nd}} \text{ modèle: } \hat{Y} = 1.075 + 0.492X$$

$$F = \frac{0.1818/2}{0.3272/4} = 1.11 \sim F_{2,4}(\alpha) \text{ seuil.}$$

À un seuil $\alpha = 5\%$ par exemple,

$$F > F_{2,4}(\alpha)$$

Considérez donc le modèle d.