

STT5100 — Modèles linéaires appliqués

111 Exercices pour se pratiquer

Pour chaque question, plusieurs réponses sont proposées. Une seule réponse est correcte.

Partie I — Modèle linéaire estimé par moindres carrés ordinaires

1. On estime deux modèles :

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

et

$$y_i = \gamma_0 + \gamma_1(x_i - \bar{x}) + u_i.$$

Quelle affirmation est vraie ?

- A) $\gamma_1 = 0$ car la variable est centrée.
- B) $\gamma_1 = \beta_1$.
- C) $\gamma_0 = \beta_0$.
- D) Le R^2 du second modèle est toujours plus grand.
- E) Aucune des réponses proposées.

2. Dans le modèle

$$\mathbb{E}[Y \mid x, \text{zone}] = \beta_0 + \beta_1 x + \beta_2 \mathbf{1}_{\{\text{zone}=B\}},$$

la zone A est la référence. Comment interpréter $\hat{\beta}_2 = 3.2$?

- A) La moyenne de Y en zone B vaut 3.2.
- B) À x fixé, la moyenne de Y en zone B est supérieure de 3.2 à celle en zone A .
- C) Quand x augmente d'une unité, Y augmente de 3.2 en zone B .
- D) La zone B explique 3.2% de la variance.
- E) Aucune des réponses proposées.

3. On estime

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + \beta_3 x_i z_i + \varepsilon_i,$$

où $z_i \in \{0, 1\}$. Quel est l'effet marginal de x lorsque $z = 1$?

- A) β_1 .
- B) β_2 .
- C) $\beta_1 + \beta_3$.
- D) $\beta_2 + \beta_3$.
- E) Aucune des réponses proposées.

4. Le vrai modèle est

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon,$$

avec $\beta_2 > 0$ et $\text{Cov}(X_1, X_2) > 0$. Si l'on estime seulement Y sur X_1 , que peut-on dire du coefficient de X_1 ?

- A) Il est toujours égal à β_1 .
- B) Il est biaisé vers le bas.
- C) Il est biaisé vers le haut.
- D) Il vaut nécessairement zéro.
- E) Aucune des réponses proposées.

5. Lorsqu'on ajoute une variable explicative dans une régression linéaire avec constante :

- A) le R^2 ne peut pas diminuer.
- B) le R^2 ajusté ne peut pas diminuer.
- C) le R^2 et le R^2 ajusté augmentent toujours.
- D) l'écart-type résiduel augmente toujours.
- E) Aucune des réponses proposées.

6. Une observation a un fort levier, ou *high leverage*, si :

- A) son résidu est très grand.
- B) sa valeur de Y est extrême.
- C) ses variables explicatives sont atypiques.
- D) elle est nécessairement mal prédite.
- E) Aucune des réponses proposées.

7. En présence d'hétéroscédasticité, si $\mathbb{E}[\varepsilon | X] = 0$, les estimateurs MCO sont :

- A) nécessairement biaisés.
- B) encore centrés, mais les écarts-types usuels peuvent être incorrects.
- C) inutilisables car le R^2 n'a plus de sens.
- D) identiques aux estimateurs de moindres carrés pondérés.
- E) Aucune des réponses proposées.

8. Dans un modèle

$$\log(Y) = \beta_0 + \beta_1 x + \varepsilon,$$

on obtient $\hat{\beta}_1 = 0.04$. Une augmentation d'une unité de x est associée approximativement à :

- A) une hausse de Y de 0.04 unité.
- B) une hausse de Y de 4%.
- C) une baisse de Y de 4%.
- D) une hausse de $\log(Y)$ de 4 unités.
- E) Aucune des réponses proposées.

9. L'écart-type résiduel d'un modèle linéaire vaut 5. Cela signifie :

- A) les erreurs de prédiction valent toutes exactement 5.
- B) la moyenne des résidus vaut 5.
- C) les résidus ont une dispersion typique d'environ 5 unités de Y .
- D) le R^2 vaut 0.5.
- E) Aucune des réponses proposées.

10. Pour une même valeur x_0 , l'intervalle de prédiction d'une nouvelle observation est généralement :

- A) plus étroit que l'intervalle de confiance de $\mathbb{E}[Y | X = x_0]$.
- B) de même largeur.
- C) plus large.

- D) toujours centré en zéro.
E) Aucune des réponses proposées.
11. On estime un modèle linéaire avec deux variables X_1 et X_2 . Si X_1 et X_2 sont très corrélées, alors :
- A) les estimateurs des coefficients sont nécessairement biaisés.
B) les écarts-types des coefficients peuvent être élevés.
C) le R^2 devient nécessairement négatif.
D) les résidus ont nécessairement une moyenne non nulle.
E) Aucune des réponses proposées.
12. On compare deux modèles emboîtés, $\mathcal{M}_0$ et $\mathcal{M}_1$, où $\mathcal{M}_0$ est obtenu en imposant une restriction linéaire à $\mathcal{M}_1$. Le test usuel de comparaison des deux modèles est :
- A) un test de Student sur la constante uniquement.
B) un test de Fisher.
C) un test de Kolmogorov–Smirnov.
D) un test de normalité des résidus.
E) Aucune des réponses proposées.
13. On utilise la base `stackloss`, disponible dans le package R `datasets`. Elle contient 21 observations et 4 variables : `Air.Flow`, `Water.Temp`, `Acid.Conc` et `stack.loss`. On estime le modèle suivant :

```
data(stackloss)
reg <- lm(stack.loss ~ Air.Flow + Water.Temp + Acid.Conc,
          data = stackloss)
summary(reg)
```

La sortie obtenue est partiellement masquée :

```
Call:
lm(formula = stack.loss ~ Air.Flow + Water.Temp + Acid.Conc,
    data = stackloss)

Residuals:
    Min       1Q   Median       3Q      Max
-7.237  -1.712  -0.456   2.361   5.698

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -39.9197    11.8960  -3.356  0.00375 **
Air.Flow       0.7156     0.1349   ???    0.000058 ***
Water.Temp     1.2953     0.3680   3.520  0.00263 **
Acid.Conc     -0.1521     0.1563  -0.973  0.34405

Residual standard error: 3.243 on 17 degrees of freedom
Multiple R-squared: 0.9136, Adjusted R-squared: ???
F-statistic: 59.90 on 3 and 17 DF, p-value: 3.02e-09
```

Quelle est environ la valeur masquée du t -statistic de `Air.Flow`?

- A) 0.19.
B) 1.35.
C) 5.31.
D) 9.14.

- E) Aucune des réponses proposées.
14. Au seuil de 5%, quelle variable n'est pas significative dans ce modèle ?
- A) `Air.Flow`.
 B) `Water.Temp`.
 C) `Acid.Conc`.
 D) Toutes les variables sont significatives.
 E) Aucune des réponses proposées.
15. Combien d'observations ont été utilisées dans la régression précédente ?
- A) 17.
 B) 18.
 C) 20.
 D) 21.
 E) On ne peut pas savoir.
16. Quelle est l'interprétation de $\hat{\beta}_{\text{Air.Flow}} = 0.7156$?
- A) Une hausse d'une unité de `Air.Flow` augmente la valeur prédite de `stack.loss` d'environ 0.716, toutes choses égales par ailleurs.
 B) Une hausse d'une unité de `Air.Flow` multiplie la valeur prédite par 0.716.
 C) Une hausse d'une unité de `Air.Flow` augmente la probabilité de `stack.loss` de 0.716.
 D) `Air.Flow` explique 71.56% de la variance.
 E) Aucune des réponses proposées.
17. Une approximation de l'intervalle de confiance à 95% pour le coefficient de `Air.Flow` est :
- A) [0.01; 0.28].
 B) [-0.15; 0.72].
 C) [0.43; 1.00].
 D) [1.00; 1.43].
 E) Aucune des réponses proposées.
18. Pour une observation avec

`Air.Flow` = 60, `Water.Temp` = 20, `Acid.Conc` = 85,

la prédiction vaut environ :

- A) 4.1.
 B) 16.0.
 C) 28.4.
 D) 60.0.
 E) Aucune des réponses proposées.

19. On estime aussi le modèle réduit :

```
reg0 <- lm(stack.loss ~ Air.Flow + Water.Temp, data = stackloss)
```

On obtient :

```
RSS(reg0) = 188.80
RSS(reg)  = 178.83
```

Le test de comparaison entre `reg0` et `reg` revient ici à tester :

- A) si `Air.Flow` est utile.
- B) si `Water.Temp` est utile.
- C) si `Acid.Conc` apporte quelque chose en plus des deux autres variables.
- D) si la constante est nulle.
- E) Aucune des réponses proposées.

20. Sachant que la p -value associée à `Acid.Conc` vaut 0.344, que conclure au seuil de 5% ?

- A) On rejette le modèle complet.
- B) On garde nécessairement `Acid.Conc` car le R^2 est élevé.
- C) On n'a pas d'évidence statistique forte que `Acid.Conc` améliore le modèle une fois `Air.Flow` et `Water.Temp` inclus.
- D) Le modèle linéaire est impossible car il y a 21 observations.
- E) Aucune des réponses proposées.

21. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On remplace ensuite X_i par $Z_i = 10X_i$. Quel est le lien entre le coefficient de Z et celui de X ?

- A) Le coefficient de Z vaut $10\hat{\beta}_1$
- B) Le coefficient de Z vaut $\hat{\beta}_1/10$
- C) Le coefficient de Z vaut $\hat{\beta}_1$
- D) Le coefficient de Z vaut $\hat{\beta}_1^2$
- E) aucune des réponses proposées

22. Dans une régression linéaire avec constante, la somme des résidus vaut :

- A) toujours 1
- B) toujours 0
- C) toujours égale au R^2
- D) toujours égale à la variance résiduelle
- E) aucune des réponses proposées

23. On estime un modèle linéaire simple avec constante. La droite ajustée passe nécessairement par :

- A) le point $(0, 0)$
- B) le point $(\bar{X}, \bar{Y})$
- C) le point $(\hat{\beta}_0, \hat{\beta}_1)$
- D) l'observation ayant le plus grand levier
- E) aucune des réponses proposées

24. Dans un modèle linéaire, une variable explicative qualitative à 4 modalités est introduite avec une constante. Combien de variables indicatrices doit-on inclure ?

- A) 1
- B) 2
- C) 3
- D) 4
- E) aucune des réponses proposées

25. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $\hat{\beta}_1 = 2$ et $\widehat{\text{se}}(\hat{\beta}_1) = 0.5$. Quelle est la statistique de test de $H_0 : \beta_1 = 0$?

- A) 0.25
- B) 1
- C) 2
- D) 4
- E) aucune des réponses proposées

26. Dans un modèle linéaire, un intervalle de confiance à 95% pour β_1 est donné approximativement par :

- A) $\hat{\beta}_1 \pm 1.96 \widehat{\text{se}}(\hat{\beta}_1)$
- B) $\hat{\beta}_1 \pm R^2$
- C) $\hat{\beta}_1 \pm \hat{\sigma}^2$
- D) $\hat{\beta}_1 / \widehat{\text{se}}(\hat{\beta}_1)$
- E) aucune des réponses proposées

27. Si une variable explicative est presque parfaitement corrélée avec une autre variable explicative, on parle généralement :

- A) d'hétéroscédasticité
- B) d'autocorrélation
- C) de multicolinéarité
- D) d'endogénéité parfaite
- E) aucune des réponses proposées

28. Une forte multicolinéarité a généralement pour conséquence :

- A) de rendre les estimateurs MCO nécessairement biaisés
- B) d'augmenter l'incertitude sur certains coefficients estimés
- C) de rendre le R^2 toujours nul
- D) de supprimer automatiquement la constante
- E) aucune des réponses proposées

29. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Si $\hat{\beta}_1 < 0$, alors :

- A) X et Y sont positivement corrélés
- B) X et Y sont négativement corrélés
- C) le modèle est nécessairement faux
- D) le R^2 est nécessairement négatif
- E) aucune des réponses proposées

30. Dans une régression linéaire avec constante, le coefficient de détermination R^2 mesure :

- A) la proportion de variance de Y expliquée par le modèle
- B) la moyenne des résidus
- C) la variance de X
- D) la probabilité que le modèle soit vrai

- E) aucune des réponses proposées
- 31.** On compare deux modèles emboîtés. Le modèle complet contient toutes les variables du modèle réduit, plus une variable supplémentaire. Le test de Fisher de comparaison teste :
- A) si la variable supplémentaire améliore significativement l'ajustement
 - B) si les résidus sont normaux
 - C) si le R^2 est supérieur à 1
 - D) si toutes les observations sont indépendantes
 - E) aucune des réponses proposées
- 32.** On estime un modèle linéaire avec $n = 100$ observations et $p = 4$ paramètres, constante incluse. Le nombre de degrés de liberté résiduels est :
- A) 100
 - B) 99
 - C) 96
 - D) 4
 - E) aucune des réponses proposées
- 33.** Dans un graphique résidus contre valeurs ajustées, un motif en forme d'entonnoir suggère souvent :
- A) une hétéroscédasticité
 - B) une absence totale de relation entre X et Y
 - C) une colinéarité parfaite
 - D) une variable qualitative mal codée
 - E) aucune des réponses proposées
- 34.** On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Si l'on ajoute une constante c à toutes les valeurs de Y , que devient le coefficient de pente ?

- A) Il augmente de c
 - B) Il diminue de c
 - C) Il est inchangé
 - D) Il est multiplié par c
 - E) aucune des réponses proposées
- 35.** Dans un modèle linéaire, une observation influente est une observation :
- A) dont la suppression modifie fortement les coefficients estimés
 - B) dont le résidu est forcément nul
 - C) dont la valeur de Y est toujours moyenne
 - D) dont le poids statistique est toujours égal à zéro
 - E) aucune des réponses proposées

- 36.** On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $\hat{\beta}_0 = 3$ et $\hat{\beta}_1 = 2$. Quelle est la valeur prédite pour $X = 4$?

- A) 5
- B) 8

- C) 11
- D) 14
- E) aucune des réponses proposées

37. Le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$$

est :

- A) non linéaire en les paramètres
- B) linéaire en les paramètres
- C) impossible à estimer par moindres carrés
- D) un modèle logistique
- E) aucune des réponses proposées

38. Dans le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i,$$

l'effet marginal de X sur l'espérance conditionnelle de Y est :

- A) β_1
- B) β_2
- C) $\beta_1 + \beta_2$
- D) $\beta_1 + 2\beta_2 X$
- E) aucune des réponses proposées

39. On estime un modèle avec une variable qualitative **region** ayant trois modalités : A, B, C. La modalité A est la référence. Si le coefficient associé à **regionB** vaut -2 , alors :

- A) la moyenne prédite en région B est inférieure de 2 à celle de la région A, toutes choses égales par ailleurs
- B) la moyenne prédite en région B est égale à -2
- C) la région B est supprimée du modèle
- D) la variable **region** n'est pas significative
- E) aucune des réponses proposées

40. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $R^2 = 0.64$. Dans une régression simple avec constante, la corrélation empirique entre X et Y vaut :

- A) nécessairement 0.64
- B) nécessairement 0.80
- C) nécessairement -0.80
- D) soit 0.80, soit -0.80 , selon le signe de $\hat{\beta}_1$
- E) aucune des réponses proposées

41. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On remplace ensuite X_i par $Z_i = 10X_i$. Quel est le lien entre le coefficient de Z et celui de X ?

- A) Le coefficient de Z vaut $10\hat{\beta}_1$
- B) Le coefficient de Z vaut $\hat{\beta}_1/10$
- C) Le coefficient de Z vaut $\hat{\beta}_1$

- D) Le coefficient de Z vaut $\hat{\beta}_1^2$
 E) aucune des réponses proposées
- 42.** Dans une régression linéaire avec constante, la somme des résidus vaut :
- A) toujours 1
 B) toujours 0
 C) toujours égale au R^2
 D) toujours égale à la variance résiduelle
 E) aucune des réponses proposées
- 43.** On estime un modèle linéaire simple avec constante. La droite ajustée passe nécessairement par :
- A) le point $(0, 0)$
 B) le point $(\bar{X}, \bar{Y})$
 C) le point $(\hat{\beta}_0, \hat{\beta}_1)$
 D) l'observation ayant le plus grand levier
 E) aucune des réponses proposées
- 44.** Dans un modèle linéaire, une variable explicative qualitative à 4 modalités est introduite avec une constante. Combien de variables indicatrices doit-on inclure ?
- A) 1
 B) 2
 C) 3
 D) 4
 E) aucune des réponses proposées
- 45.** On estime
- $$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$
- On obtient $\hat{\beta}_1 = 2$ et $\widehat{\text{se}}(\hat{\beta}_1) = 0.5$. Quelle est la statistique de test de $H_0 : \beta_1 = 0$?
- A) 0.25
 B) 1
 C) 2
 D) 4
 E) aucune des réponses proposées
- 46.** Dans un modèle linéaire, un intervalle de confiance à 95% pour β_1 est donné approximativement par :
- A) $\hat{\beta}_1 \pm 1.96 \widehat{\text{se}}(\hat{\beta}_1)$
 B) $\hat{\beta}_1 \pm R^2$
 C) $\hat{\beta}_1 \pm \hat{\sigma}^2$
 D) $\hat{\beta}_1 / \widehat{\text{se}}(\hat{\beta}_1)$
 E) aucune des réponses proposées
- 47.** Si une variable explicative est presque parfaitement corrélée avec une autre variable explicative, on parle généralement :
- A) d'hétéroscédasticité
 B) d'autocorrélation

- C) de multicolinéarité
- D) d'endogénéité parfaite
- E) aucune des réponses proposées

48. Une forte multicolinéarité a généralement pour conséquence :

- A) de rendre les estimateurs MCO nécessairement biaisés
- B) d'augmenter l'incertitude sur certains coefficients estimés
- C) de rendre le R^2 toujours nul
- D) de supprimer automatiquement la constante
- E) aucune des réponses proposées

49. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Si $\hat{\beta}_1 < 0$, alors :

- A) X et Y sont positivement corrélés
- B) X et Y sont négativement corrélés
- C) le modèle est nécessairement faux
- D) le R^2 est nécessairement négatif
- E) aucune des réponses proposées

50. Dans une régression linéaire avec constante, le coefficient de détermination R^2 mesure :

- A) la proportion de variance de Y expliquée par le modèle
- B) la moyenne des résidus
- C) la variance de X
- D) la probabilité que le modèle soit vrai
- E) aucune des réponses proposées

51. On compare deux modèles emboîtés. Le modèle complet contient toutes les variables du modèle réduit, plus une variable supplémentaire. Le test de Fisher de comparaison teste :

- A) si la variable supplémentaire améliore significativement l'ajustement
- B) si les résidus sont normaux
- C) si le R^2 est supérieur à 1
- D) si toutes les observations sont indépendantes
- E) aucune des réponses proposées

52. On estime un modèle linéaire avec $n = 100$ observations et $p = 4$ paramètres, constante incluse. Le nombre de degrés de liberté résiduels est :

- A) 100
- B) 99
- C) 96
- D) 4
- E) aucune des réponses proposées

53. Dans un graphique résidus contre valeurs ajustées, un motif en forme d'entonnoir suggère souvent :

- A) une hétéroscédasticité
- B) une absence totale de relation entre X et Y

- C) une colinéarité parfaite
- D) une variable qualitative mal codée
- E) aucune des réponses proposées

54. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Si l'on ajoute une constante c à toutes les valeurs de Y , que devient le coefficient de pente ?

- A) Il augmente de c
- B) Il diminue de c
- C) Il est inchangé
- D) Il est multiplié par c
- E) aucune des réponses proposées

55. Dans un modèle linéaire, une observation influente est une observation :

- A) dont la suppression modifie fortement les coefficients estimés
- B) dont le résidu est forcément nul
- C) dont la valeur de Y est toujours moyenne
- D) dont le poids statistique est toujours égal à zéro
- E) aucune des réponses proposées

56. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $\hat{\beta}_0 = 3$ et $\hat{\beta}_1 = 2$. Quelle est la valeur prédite pour $X = 4$?

- A) 5
- B) 8
- C) 11
- D) 14
- E) aucune des réponses proposées

57. Le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$$

est :

- A) non linéaire en les paramètres
- B) linéaire en les paramètres
- C) impossible à estimer par moindres carrés
- D) un modèle logistique
- E) aucune des réponses proposées

58. Dans le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i,$$

l'effet marginal de X sur l'espérance conditionnelle de Y est :

- A) β_1
- B) β_2
- C) $\beta_1 + \beta_2$
- D) $\beta_1 + 2\beta_2 X$
- E) aucune des réponses proposées

59. On estime un modèle avec une variable qualitative **region** ayant trois modalités : A, B, C. La modalité A est la référence. Si le coefficient associé à **regionB** vaut -2 , alors :

- A) la moyenne prédite en région B est inférieure de 2 à celle de la région A, toutes choses égales par ailleurs
- B) la moyenne prédite en région B est égale à -2
- C) la région B est supprimée du modèle
- D) la variable **region** n'est pas significative
- E) aucune des réponses proposées

60. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $R^2 = 0.64$. Dans une régression simple avec constante, la corrélation empirique entre X et Y vaut :

- A) nécessairement 0.64
- B) nécessairement 0.80
- C) nécessairement -0.80
- D) soit 0.80, soit -0.80 , selon le signe de $\hat{\beta}_1$
- E) aucune des réponses proposées

Partie II — Modèles linéaires généralisés : logistique et Poisson

61. Dans une régression logistique, on a

$$\log\left(\frac{p}{1-p}\right) = -1 + 0.5x.$$

Pour $x = 2$, la probabilité prédite p vaut :

- A) 0
- B) 0.5
- C) 0.73
- D) 1
- E) aucune des réponses proposées

62. Dans une régression logistique, un coefficient $\hat{\beta} = 0.8$ associé à une variable X signifie que, lorsque X augmente d'une unité, toutes choses égales par ailleurs :

- A) la probabilité est multipliée par 0.8
- B) la probabilité augmente de 80%
- C) les odds sont multipliées par $\exp(0.8)$
- D) les odds diminuent de $\exp(0.8)$
- E) aucune des réponses proposées

63. On estime une régression logistique avec une variable qualitative **sexe**, où **Homme** est la référence. Le coefficient associé à **sexeFemme** vaut -0.4 . On peut dire que :

- A) les femmes ont une probabilité négative
- B) les femmes ont des odds multipliées par $\exp(-0.4)$ par rapport aux hommes, toutes choses égales par ailleurs
- C) les femmes ont une probabilité inférieure de 40 points de pourcentage

- D) le modèle est impossible à interpréter
- E) aucune des réponses proposées

64. On estime

$$\log\left(\frac{p}{1-p}\right) = -2 + 1.5x.$$

Pour $x = 1$, la probabilité prédite est approximativement :

- A) 0.12
- B) 0.27
- C) 0.38
- D) 0.82
- E) aucune des réponses proposées

65. Dans un modèle logistique, la règle de classification $\hat{p} > 0.5$ est équivalente à :

- A) $\hat{\eta} < 0$, où $\hat{\eta}$ est le prédicteur linéaire
- B) $\hat{\eta} = 0$
- C) $\hat{\eta} < 1$
- D) $\hat{\eta} > 0$
- E) aucune des réponses proposées

66. Dans une régression de Poisson avec lien logarithmique,

$$\log(\mathbb{E}[Y|X]) = \beta_0 + \beta_1 X.$$

Si $\hat{\beta}_1 = 0.2$, alors une hausse d'une unité de X multiplie l'espérance conditionnelle par environ :

- A) 0.2
- B) 1.02
- C) 1.22
- D) 2
- E) aucune des réponses proposées

67. Dans un modèle de Poisson avec offset,

$$\log(\mathbb{E}[N|X, E]) = \log(E) + \beta_0 + \beta_1 X.$$

À X fixé, si l'exposition E double, alors l'espérance de N :

- A) reste inchangée
- B) double
- C) est divisée par deux
- D) augmente de β_1
- E) aucune des réponses proposées

68. Dans un modèle de Poisson standard, on suppose que :

- A) $\text{Var}(Y|X) = 1$
- B) $\text{Var}(Y|X) = \mathbb{E}[Y|X]$
- C) $\text{Var}(Y|X) = 0$
- D) $\text{Var}(Y|X)$ est toujours supérieure au carré de l'espérance
- E) aucune des réponses proposées

- 69.** Dans un GLM de Poisson, on observe une déviance résiduelle de 95 pour 30 degrés de liberté. Cela suggère plutôt :
- A) une sous-dispersion très forte
 - B) une absence totale de relation entre X et Y
 - C) une possible surdispersion
 - D) une séparation parfaite
 - E) aucune des réponses proposées
- 70.** En présence de surdispersion dans un modèle de Poisson, une approche possible est :
- A) d'utiliser une régression linéaire sans constante
 - B) d'utiliser un modèle quasi-Poisson ou binomial négatif
 - C) de supprimer toutes les observations avec $Y = 0$
 - D) de remplacer le lien logarithmique par une fonction constante
 - E) aucune des réponses proposées
- 71.** On compare deux GLM emboîtés. Le modèle réduit a une déviance résiduelle de 120.5, le modèle complet une déviance résiduelle de 108.1. Le modèle complet ajoute 2 paramètres. La statistique du test du rapport de vraisemblance vaut :
- A) 2
 - B) 12.4
 - C) $108.1/120.5$
 - D) $120.5 + 108.1$
 - E) aucune des réponses proposées
- 72.** Pour comparer deux modèles estimés par maximum de vraisemblance sur les mêmes données, l'AIC :
- A) doit toujours être le plus grand possible
 - B) est égal au R^2
 - C) pénalise la complexité du modèle
 - D) ne dépend pas de la vraisemblance
 - E) aucune des réponses proposées
- 73.** On estime le modèle logistique

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i,$$

où $D_i = 1$ pour le groupe B et 0 pour le groupe A. L'effet de X sur le log-odds dans le groupe B est :

- A) β_1
 - B) β_2
 - C) β_3
 - D) $\beta_1 + \beta_3$
 - E) aucune des réponses proposées
- 74.** Dans le même modèle,

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i,$$

l'écart de log-odds entre le groupe B et le groupe A, pour une valeur $X = x$, est :

- A) β_2
- B) β_3
- C) $\beta_2 + \beta_3 x$
- D) $\beta_1 + \beta_2 + \beta_3$
- E) aucune des réponses proposées

75. Si l'on transforme une variable binaire Y en $1 - Y$ et que l'on réestime une régression logistique avec les mêmes variables explicatives, alors :

- A) les coefficients changent de signe
- B) les coefficients sont inchangés
- C) les probabilités prédites sont inchangées
- D) le modèle devient un modèle de Poisson
- E) aucune des réponses proposées

76. Dans un GLM, la fonction de lien g relie :

- A) les résidus aux variables explicatives
- B) la variance à la déviance
- C) l'espérance conditionnelle au prédicteur linéaire
- D) l'AIC au BIC
- E) aucune des réponses proposées

77. Le modèle linéaire classique avec erreurs normales peut être vu comme un GLM avec :

- A) loi de Poisson et lien logarithmique
- B) loi binomiale et lien logit
- C) loi normale et lien identité
- D) loi exponentielle et lien logit
- E) aucune des réponses proposées

78. On estime un modèle de Poisson avec offset :

$$\log(\mu_i) = \log(E_i) - 4 + 0.5X_i.$$

Pour $E_i = 100$ et $X_i = 1$, la moyenne prédite μ_i vaut approximativement :

- A) 0.03
- B) 0.30
- C) 3.02
- D) 30.2
- E) aucune des réponses proposées

79. Dans une régression logistique, une séparation parfaite des données peut conduire à :

- A) des coefficients estimés très grands en valeur absolue ou non finis
- B) un R^2 exactement égal à 1 au sens des moindres carrés
- C) une variance résiduelle négative
- D) une loi de Poisson
- E) aucune des réponses proposées

80. Dans un modèle logistique, les effets marginaux sur la probabilité :

- A) sont toujours égaux aux coefficients du modèle

- B) sont constants pour toutes les valeurs de X
- C) dépendent généralement de la valeur des variables explicatives
- D) sont toujours nuls lorsque le coefficient est positif
- E) aucune des réponses proposées

81. Dans R, la commande

```
glm(y ~ x1 + x2, family = binomial, data = base)
```

avec une variable réponse binaire $Y \in \{0, 1\}$ estime les paramètres :

- A) par moindres carrés ordinaires
- B) par minimisation de la somme des résidus absolus
- C) par la méthode des moments uniquement
- D) par maximum de vraisemblance
- E) aucune des réponses proposées

82. On estime une régression logistique

$$\log\left(\frac{p}{1-p}\right) = -3 + 0.04 \text{ age}.$$

Une hausse de 10 ans de l'âge multiplie les odds par environ :

- A) $\exp(0.04)$
- B) 0.4
- C) $\exp(0.4)$
- D) $10 \exp(0.04)$
- E) aucune des réponses proposées

83. Si une probabilité vaut $p = 0.8$, alors le logit de p vaut :

- A) 0.8
- B) $\log(4) \simeq 1.386$
- C) 4
- D) -1.386
- E) aucune des réponses proposées

84. Dans une régression logistique, on classe une observation en classe 1 si $\hat{p} > 0.2$. Cette règle est équivalente à :

- A) $\hat{\eta} > 0$, où $\hat{\eta}$ est le prédicteur linéaire
- B) $\hat{\eta} > 0.2$
- C) $\hat{\eta} > \log(0.2)$
- D) $\hat{\eta} > \log(0.2/0.8)$
- E) aucune des réponses proposées

85. Pour des données binomiales groupées, on peut écrire dans R :

```
glm(cbind(succes, echec) ~ x, family = binomial).
```

Ici, la première colonne de `cbind` représente :

- A) les probabilités estimées
- B) les résidus du modèle

- C) le nombre de succès
- D) le nombre total d'observations uniquement
- E) aucune des réponses proposées

86. Si Y_i est le nombre de succès parmi m_i essais, et si

$$Y_i | X_i \sim \text{Binomial}(m_i, p_i),$$

alors la variance de la proportion Y_i/m_i conditionnellement à X_i est :

- A) p_i
- B) $m_i p_i (1 - p_i)$
- C) $p_i (1 - p_i)$
- D) $p_i (1 - p_i) / m_i$
- E) aucune des réponses proposées

87. Dans un modèle de Poisson avec lien logarithmique, un coefficient estimé vaut $\hat{\beta} = -0.7$. Une hausse d'une unité de la variable associée :

- A) soustrait 0.7 à l'espérance
- B) multiplie l'espérance par $\exp(-0.7)$
- C) divise nécessairement l'espérance par 0.7
- D) rend l'espérance négative
- E) aucune des réponses proposées

88. Dans un modèle de Poisson pour un nombre de sinistres N_i , l'utilisation de

$$\log(E_i)$$

comme offset signifie que son coefficient est :

- A) fixé à 1
- B) estimé librement
- C) fixé à 0
- D) toujours égal à la constante du modèle
- E) aucune des réponses proposées

89. Au lieu d'utiliser un offset, on estime

$$\log(\mu_i) = \beta_0 + \alpha \log(E_i) + \beta_1 X_i.$$

Le modèle avec offset correspond au cas :

- A) $\alpha = 1$
- B) $\alpha = 0$
- C) $\alpha = \beta_1$
- D) $\alpha = -1$
- E) aucune des réponses proposées

90. Dans un GLM Gamma avec lien logarithmique,

$$\log(\mathbb{E}[Y|X]) = \beta_0 + \beta_1 X.$$

Si $\hat{\beta}_1 = 0.1$, alors une hausse d'une unité de X :

- A) augmente l'espérance de 0.1

- B) augmente l'espérance de 10 unités
 C) multiplie l'espérance par $\exp(0.1)$
 D) diminue toujours l'espérance
 E) aucune des réponses proposées
- 91.** Dans un GLM Gamma standard, la variance conditionnelle est généralement modélisée comme proportionnelle à :
- A) μ
 B) μ^2
 C) $\sqrt{\mu}$
 D) $1/\mu$
 E) aucune des réponses proposées
- 92.** On compare deux modèles logistiques emboîtés. Le modèle réduit a une déviance résiduelle de 210, le modèle complet une déviance résiduelle de 185. Le modèle complet ajoute deux paramètres. La statistique du test du rapport de vraisemblance vaut :
- A) 2
 B) 12.5
 C) 25
 D) 395
 E) aucune des réponses proposées
- 93.** Pour un modèle estimé par maximum de vraisemblance, l'AIC est défini par :
- A) $-2 \log L + 2k$, où k est le nombre de paramètres
 B) R^2/k
 C) $\log L - 2k$
 D) $2 \log L + k$
 E) aucune des réponses proposées
- 94.** Par rapport à l'AIC, le BIC :
- A) ne pénalise jamais la complexité
 B) est toujours égal à l'AIC
 C) pénalise la complexité par un terme en $k \log(n)$
 D) ne dépend pas du nombre d'observations
 E) aucune des réponses proposées
- 95.** Pour un objet `glm` dans R, la commande
- $$\text{predict}(\text{reg}, \text{type} = \text{"response"})$$
- retourne généralement :
- A) le prédicteur linéaire $\hat{\eta}_i$
 B) la prédiction sur l'échelle de la réponse, par exemple $\hat{p}_i$ pour un modèle logistique
 C) uniquement les résidus
 D) uniquement les erreurs standards
 E) aucune des réponses proposées
- 96.** Pour construire un intervalle de confiance sur une probabilité prédite dans un modèle logistique, une méthode courante consiste à :

- A) construire l'intervalle directement sur les résidus
 - B) utiliser uniquement le R^2
 - C) construire un intervalle sur l'échelle de la réponse puis appliquer le logit
 - D) construire un intervalle sur l'échelle du lien puis appliquer la fonction logistique inverse
 - E) aucune des réponses proposées
97. Dans un problème de classification binaire, si l'on augmente le seuil de classification de 0.5 à 0.8, alors, en général :
- A) la sensibilité augmente et la spécificité diminue
 - B) la sensibilité diminue et la spécificité augmente
 - C) la sensibilité et la spécificité restent toujours inchangées
 - D) l'AUC devient nécessairement égale à 1
 - E) aucune des réponses proposées
98. Une AUC proche de 0.5 signifie généralement que le score :
- A) classe parfaitement les observations
 - B) est inutilisable car toutes les probabilités sont négatives
 - C) discrimine peu mieux qu'un classement aléatoire
 - D) garantit une excellente calibration
 - E) aucune des réponses proposées
99. Dans un modèle quasi-Poisson, on estime un paramètre de dispersion ϕ . Si la statistique de Pearson vaut 75 pour 50 degrés de liberté, une estimation naturelle de ϕ est :
- A) 0.67
 - B) 1
 - C) 1.5
 - D) 125
 - E) aucune des réponses proposées
100. Si l'on ajuste un modèle de Poisson alors qu'il y a une forte surdispersion non prise en compte, les erreurs standards usuelles sont souvent :
- A) trop petites, ce qui peut rendre les tests trop optimistes
 - B) exactement correctes
 - C) toujours infinies
 - D) toujours nulles
 - E) aucune des réponses proposées
101. Dans une régression logistique, un coefficient $\hat{\beta} = 0.7$ signifie que, toutes choses égales par ailleurs :
- A) la probabilité est multipliée par 0.7.
 - B) la probabilité augmente de 70 points de pourcentage.
 - C) les *odds* sont multipliées par $\exp(0.7)$.
 - D) les *odds* diminuent de 70%.
 - E) Aucune des réponses proposées.
102. Dans un modèle logistique, si le prédicteur linéaire vaut

$$\eta = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 = 0,$$

quelle est la valeur prédite de $\mathbb{P}[Y = 1 \mid x_1, x_2]$?

- A) 0.25.
- B) 0.5.
- C) 0.75.
- D) 1.
- E) Aucune des réponses proposées.

103. Dans une régression de Poisson avec offset,

$$\log(\mathbb{E}[N | X, E]) = \log(E) + \beta_0 + \beta_1 X,$$

si $\hat{\beta}_1 = 0.3$, alors le passage de $X = 0$ à $X = 1$ multiplie le taux par environ :

- A) 0.30.
- B) 1.30.
- C) $\exp(0.3)$.
- D) $\log(0.3)$.
- E) Aucune des réponses proposées.

104. On utilise la base `Titanic`, disponible dans le package R `datasets`. On agrège les effectifs par classe, sexe et âge, puis on estime une régression logistique de la survie :

```
tt <- as.data.frame(Titanic)
wide <- reshape(tt, idvar = c("Class", "Sex", "Age"),
                timevar = "Survived", direction = "wide")
names(wide)[names(wide) == "Freq.No"] <- "No"
names(wide)[names(wide) == "Freq.Yes"] <- "Yes"
wide <- subset(wide, Yes + No > 0)

reg_logit <- glm(cbind(Yes, No) ~ Class + Sex + Age,
                family = binomial, data = wide)
summary(reg_logit)
```

La sortie est partiellement donnée ci-dessous :

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   0.6853     0.2730   2.510   0.0121 *
Class2nd      -1.0181     0.1960  -5.194   2.1e-07 ***
Class3rd      -1.7778     0.1716 -10.362   < 2e-16 ***
ClassCrew     -0.8577     0.1573  -5.451   5.0e-08 ***
SexFemale      2.4201     0.1404  17.236   < 2e-16 ***
AgeAdult      -1.0615     0.2440  -4.350   1.4e-05 ***

Null deviance: 671.96  on 2199  degrees of freedom
Residual deviance: 112.57  on 2195  degrees of freedom
AIC: 1560.09
```

Dans ce modèle, quelle est la catégorie de référence pour `Sex` ?

- A) Female.
- B) Male.
- C) Child.
- D) Adult.
- E) Aucune des réponses proposées.

105. Dans la sortie précédente, le coefficient de `SexFemale` vaut 2.4201. Toutes choses égales par ailleurs, les *odds* de survie des femmes sont environ :

- A) divisées par 2.42 par rapport aux hommes.
- B) multipliées par 2.42 par rapport aux hommes.
- C) multipliées par $\exp(2.4201)$ par rapport aux hommes.
- D) augmentées de 2.4201 points de probabilité.
- E) Aucune des réponses proposées.

106. D'après la sortie précédente, au seuil de 5%, quelle affirmation est correcte ?

- A) La variable **AgeAdult** n'est pas significative.
- B) La variable **SexFemale** n'est pas significative.
- C) Toutes les modalités affichées ont une p -value inférieure à 5%.
- D) Le modèle logistique ne peut pas être estimé avec des données agrégées.
- E) Aucune des réponses proposées.

107. Dans le modèle logistique estimé sur **Titanic**, la valeur prédite pour un homme adulte de troisième classe est environ :

$$\hat{\eta} = 0.6853 - 1.7778 - 1.0615 = -2.1540.$$

La probabilité prédite de survie est donc environ :

- A) -2.1540.
- B) 0.104.
- C) 0.500.
- D) 0.896.
- E) Aucune des réponses proposées.

108. On compare la déviance nulle et la déviance résiduelle du modèle logistique précédent. La baisse de déviance est environ :

- A) $671.96 - 112.57$.
- B) $112.57 - 671.96$.
- C) $2199 - 2195$.
- D) $1560.09 - 112.57$.
- E) Aucune des réponses proposées.

109. On estime maintenant un modèle de Poisson sur les effectifs du tableau **Titanic** :

```
pois <- glm(Freq ~ Class + Sex + Age + Survived,
            family = poisson, data = as.data.frame(Titanic))
summary(pois)
```

Sortie partielle :

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   2.1482     0.1102  19.499 < 2e-16 ***
Class2nd      -0.1313     0.0812  -1.618  0.106
Class3rd       0.7758     0.0670  11.573 < 2e-16 ***
ClassCrew      1.0018     0.0649  15.445 < 2e-16 ***
SexFemale     -1.3037     0.0520 -25.065 < 2e-16 ***
AgeAdult       2.9545     0.0982  30.073 < 2e-16 ***
SurvivedYes   -0.7399     0.0456 -16.232 < 2e-16 ***

Null deviance: 4953.14 on 31 degrees of freedom
Residual deviance: 1243.66 on 25 degrees of freedom
```

Dans ce modèle de Poisson, le coefficient de **SurvivedYes** signifie que, toutes choses égales par ailleurs, l'espérance du nombre d'observations dans une cellule avec **Survived=Yes** est multipliée par :

- A) -0.7399 .
- B) $\exp(-0.7399)$.
- C) $1 - 0.7399$.
- D) $\log(-0.7399)$.
- E) Aucune des réponses proposées.

110. Dans la sortie du modèle de Poisson précédent, le rapport

$$\frac{\text{Residual deviance}}{\text{degrees of freedom}} = \frac{1243.66}{25}$$

est environ égal à :

- A) 0.05.
- B) 1.00.
- C) 4.97.
- D) 49.75.
- E) Aucune des réponses proposées.

111. Une valeur très élevée du rapport déviance résiduelle/degrés de liberté dans un modèle de Poisson suggère souvent :

- A) une sous-dispersion ou un ajustement parfait.
- B) une surdispersion ou un manque d'ajustement du modèle.
- C) que tous les coefficients sont nécessairement nuls.
- D) que la fonction de lien logit a été utilisée par erreur.
- E) Aucune des réponses proposées.

Réponses

Question	1	2	3	4	5	6	7	8	9	10
Réponse	B	B	C	C	A	C	B	B	C	C
Question	11	12	13	14	15	16	17	18	19	20
Réponse	B	B	C	C	D	A	C	B	C	C
Question	21	22	23	24	25	26	27	28	29	30
Réponse	B	B	B	C	D	A	C	B	B	A
Question	31	32	33	34	35	36	37	38	39	40
Réponse	A	C	A	C	A	C	B	D	A	D
Question	41	42	43	44	45	46	47	48	49	50
Réponse	B	C	B	B	A	C	D	C	C	A
Question	51	52	53	54	55	56	57	58	59	60
Réponse	C	B	B	A	B	B	C	A	C	B
Question	61	62	63	64	65	66	67	68	69	70
Réponse	B	C	B	C	D	C	B	B	C	B
Question	71	72	73	74	75	76	77	78	79	80
Réponse	B	C	D	C	A	C	C	C	A	C
Question	81	82	83	84	85	86	87	88	89	90
Réponse	D	C	B	D	C	D	B	A	A	C
Question	91	92	93	94	95	96	97	98	99	100
Réponse	B	C	A	C	B	D	B	C	C	A
Question	101	102	103	104	105	106	107	108	109	100
Réponse	C	B	C	B	C	C	B	A	B	D
Question	111									
Réponse	B									