

STT5100 — Modèles linéaires appliqués

330 petits exercices pour se pratiquer

Pour chaque question, plusieurs réponses sont proposées. Une seule réponse est correcte.

Partie 1 — Rappels (algèbre linéaire, probabilités, statistiques)

1. On considère la fonction

$$f(x) = x^2 - 4x + 1.$$

La valeur de x qui minimise f est :

- A) -2
- B) 2
- C) 4
- D) 1
- E) aucune des réponses proposées

2. On considère le problème d'optimisation

$$\min_{x,y} (x-1)^2 + (y+2)^2.$$

Le minimum est atteint en :

- A) $(1, -2)$
- B) $(1/2, -1/2)$
- C) $(3/2, -3/2)$
- D) $(0, 0)$
- E) aucune des réponses proposées

3. On considère la fonction

$$f(x, y) = x^2 + 2y^2 - 6x + 8y + 10.$$

Le minimum est atteint en :

- A) $(0, 0)$
- B) $(-3, 2)$
- C) $(3, -2)$
- D) $(6, -8)$
- E) aucune des réponses proposées

4. Soit

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x},$$

où $\mathbf{A}$ est une matrice symétrique définie positive. Le minimiseur de f est :

- A) $\mathbf{A}\mathbf{b}$
- B) $\mathbf{b}^\top \mathbf{A}\mathbf{b}$
- C) $\mathbf{A}^{-1}\mathbf{b}$
- D) $\mathbf{A} + \mathbf{b}$
- E) aucune des réponses proposées

5. Si $\mathbf{X}$ est une matrice $n \times p$, la matrice $\mathbf{X}^\top \mathbf{X}$ est inversible si :

- A) $n < p$
- B) les colonnes de $\mathbf{X}$ sont linéairement indépendantes
- C) les lignes de $\mathbf{X}$ sont toutes identiques
- D) $\mathbf{X}$ contient une constante
- E) aucune des réponses proposées

6. Si $\mathbf{X}^\top \mathbf{X}$ est inversible, la matrice

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$$

vérifie :

- A) $\mathbf{H}^\top = -\mathbf{H}$ et $\mathbf{H}^2 = 0$
- B) $\mathbf{H}^\top = \mathbf{H}$ et $\mathbf{H}^2 = \mathbf{H}$
- C) $\mathbf{H}$ est toujours diagonale
- D) $\mathbf{H}$ est toujours inversible
- E) aucune des réponses proposées

7. La projection orthogonale de $\mathbf{y}$ sur l'espace engendré par un vecteur non nul $\vec{\mathbf{a}}$ est :

- A) $\frac{\vec{\mathbf{a}}^\top \mathbf{y}}{\vec{\mathbf{a}}^\top \vec{\mathbf{a}}} \vec{\mathbf{a}}$
- B) $\frac{\mathbf{y}^\top \mathbf{y}}{\vec{\mathbf{a}}^\top \vec{\mathbf{a}}} \vec{\mathbf{a}}$
- C) $\vec{\mathbf{a}}^\top \mathbf{y}$
- D) $\mathbf{y} - \vec{\mathbf{a}}$
- E) aucune des réponses proposées

8. Si $\hat{y}$ est la projection orthogonale de y sur un sous-espace vectoriel V , alors le résidu $y - \hat{y}$ est :

- A) toujours nul
- B) dans V
- C) proportionnel à y
- D) orthogonal à V
- E) aucune des réponses proposées

9. Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors $Y = a + bX$ suit :

- A) une loi de Poisson
- B) une loi binomiale
- C) une loi normale de moyenne $a + b\mu$ et de variance $b^2\sigma^2$
- D) une loi normale de moyenne $a + \mu$ et de variance $b\sigma^2$
- E) aucune des réponses proposées

10. Si (X, Y) est un vecteur gaussien et si $\text{Cov}(X, Y) = 0$, alors :

- A) $X = Y$ presque sûrement
 - B) X et Y sont indépendantes
 - C) $X + Y = 0$ presque sûrement
 - D) X et Y suivent nécessairement la même loi
 - E) aucune des réponses proposées
11. Si $X \sim \mathcal{N}(10, 4)$, alors :
- A) $\mathbb{P}(X \leq 10) = 0$
 - B) $\mathbb{P}(X \leq 10) = 0.25$
 - C) $\mathbb{P}(X \leq 10) = 0.5$
 - D) $\mathbb{P}(X \leq 10) = 1$
 - E) aucune des réponses proposées
12. Si $X \sim \text{Binomial}(20, 0.3)$, alors :
- A) $\mathbb{E}[X] = 20$ et $\text{Var}(X) = 0.3$
 - B) $\mathbb{E}[X] = 0.3$ et $\text{Var}(X) = 20$
 - C) $\mathbb{E}[X] = 6$ et $\text{Var}(X) = 6$
 - D) $\mathbb{E}[X] = 6$ et $\text{Var}(X) = 4.2$
 - E) aucune des réponses proposées
13. Si $X \sim \text{Poisson}(\lambda)$, alors :
- A) $\mathbb{E}[X] = 0$ et $\text{Var}(X) = \lambda$
 - B) $\mathbb{E}[X] = \lambda$ et $\text{Var}(X) = \lambda$
 - C) $\mathbb{E}[X] = \lambda$ et $\text{Var}(X) = \lambda^2$
 - D) $\mathbb{E}[X] = 1/\lambda$ et $\text{Var}(X) = \lambda$
 - E) aucune des réponses proposées
14. Si $X \sim \text{Poisson}(\lambda_1)$ et $Y \sim \text{Poisson}(\lambda_2)$ sont indépendantes, alors $X + Y$ suit :
- A) une loi de Poisson de paramètre $\lambda_1 + \lambda_2$
 - B) une loi de Poisson de paramètre $\lambda_1 \lambda_2$
 - C) une loi binomiale de paramètres (λ_1, λ_2)
 - D) une loi normale centrée réduite
 - E) aucune des réponses proposées
15. Lorsque n est grand, p est petit, et $np = \lambda$, une loi $\text{Binomial}(n, p)$ peut être approximée par :
- A) une loi de Poisson de paramètre λ
 - B) une loi uniforme sur $[0, 1]$
 - C) une loi normale de moyenne 0
 - D) une loi exponentielle de paramètre p
 - E) aucune des réponses proposées
16. Si $X_1, \dots, X_n$ sont i.i.d. de moyenne μ et variance σ^2 , alors la moyenne empirique $\bar{X}$ vérifie :
- A) $\mathbb{E}[\bar{X}] = 0$
 - B) $\mathbb{E}[\bar{X}] = \mu$ et $\text{Var}(\bar{X}) = \sigma^2/n$
 - C) $\mathbb{E}[\bar{X}] = n\mu$ et $\text{Var}(\bar{X}) = \sigma^2$
 - D) $\mathbb{E}[\bar{X}] = \sigma^2$ et $\text{Var}(\bar{X}) = \mu$
 - E) aucune des réponses proposées

17. Le théorème central limite affirme, sous des conditions usuelles, que :

- A) toute variable aléatoire est normale
- B) la variance empirique est toujours nulle lorsque n est grand
- C) la moyenne empirique centrée et normalisée converge en loi vers une normale centrée réduite
- D) une loi binomiale converge toujours vers une loi uniforme
- E) aucune des réponses proposées

18. Pour un échantillon i.i.d. $X_1, \dots, X_n$, l'estimateur

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

est utilisé car :

- A) il est sans biais pour la variance sous les hypothèses usuelles
- B) il est toujours égal à zéro
- C) il est toujours égal à la moyenne
- D) il ne dépend pas des données
- E) aucune des réponses proposées

19. Si $W = 2X + 3$, alors la corrélation entre W et Y est :

- A) toujours égale à 2
- B) toujours égale à 3
- C) égale à la corrélation entre X et Y
- D) égale à zéro
- E) aucune des réponses proposées

20. Si $Y_1, \dots, Y_n$ sont i.i.d. de loi Bernoulli de paramètre p , l'estimateur du maximum de vraisemblance de p est :

- A) 0
- B) $\bar{Y}$
- C) $n\bar{Y}$
- D) $1 - \bar{Y}$
- E) aucune des réponses proposées

21. On considère la fonction

$$f(x, y) = x^2 + 2y^2 - 4x + 8y + 5.$$

Le minimum est atteint en :

- A) (0, 0)
- B) (2, -2)
- C) (-2, 2)
- D) (4, -8)
- E) aucune des réponses proposées

22. On considère la fonction

$$f(x, y) = 2x^2 + y^2 - 8x + 6y.$$

Le minimum est atteint en :

- A) $(4, -6)$
- B) $(2, -3)$
- C) $(-2, 3)$
- D) $(8, -6)$
- E) aucune des réponses proposées

23. Pour une fonction deux fois dérivable $f : \mathbb{R}^p \rightarrow \mathbb{R}$, un point critique $\mathbf{x}^*$ est un minimum local strict si :

- A) le gradient en $\mathbf{x}^*$ est non nul
- B) la matrice hessienne en $\mathbf{x}^*$ est négative définie
- C) le gradient en $\mathbf{x}^*$ est nul et la matrice hessienne en $\mathbf{x}^*$ est définie positive
- D) la fonction est constante
- E) aucune des réponses proposées

24. Si $\mathbf{X}$ est une matrice $n \times p$ et si $\mathbf{u}$ est un vecteur $p \times 1$, alors $\mathbf{X}\mathbf{u}$ est :

- A) un scalaire
- B) un vecteur $p \times 1$
- C) un vecteur $n \times 1$
- D) une matrice $p \times p$
- E) aucune des réponses proposées

25. Si deux colonnes de $\mathbf{X}$ sont exactement identiques, alors :

- A) $\mathbf{X}^\top \mathbf{X}$ est toujours inversible
- B) les colonnes de $\mathbf{X}$ ne sont pas linéairement indépendantes
- C) les moindres carrés ordinaires donnent toujours un coefficient nul
- D) la matrice $\mathbf{X}$ est nécessairement carrée
- E) aucune des réponses proposées

26. Si deux vecteurs $\vec{\mathbf{a}}$ et $\vec{\mathbf{b}}$ sont orthogonaux, alors :

- A) $\|\vec{\mathbf{a}} + \vec{\mathbf{b}}\|^2 = \|\vec{\mathbf{a}}\|^2 + \|\vec{\mathbf{b}}\|^2$
- B) $\|\vec{\mathbf{a}} + \vec{\mathbf{b}}\| = \|\vec{\mathbf{a}}\| + \|\vec{\mathbf{b}}\|$ toujours
- C) $\vec{\mathbf{a}} = \vec{\mathbf{b}}$
- D) $\vec{\mathbf{a}}^\top \vec{\mathbf{b}} = 1$
- E) aucune des réponses proposées

27. La projection orthogonale du vecteur $(3, 1)$ sur la droite engendrée par $(1, 1)$ est :

- A) $(3, 1)$
- B) $(1, 1)$
- C) $(2, 2)$
- D) $(0, 0)$
- E) aucune des réponses proposées

28. On considère les vecteurs

$$\vec{\mathbf{a}} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \text{ et } \vec{\mathbf{b}} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}.$$

Que vaut le produit scalaire $\vec{\mathbf{a}}^\top \vec{\mathbf{b}}$?

- A) -1

- B) 0
- C) 1
- D) 4
- E) aucune des réponses proposées

29. Soit X une variable aléatoire telle que

$$\mathbb{E}[X] = 10 \text{ et } \text{Var}(X) = 4.$$

Si $Y = 3 + 2X$, alors :

- A) $\mathbb{E}[Y] = 13$ et $\text{Var}(Y) = 8$
- B) $\mathbb{E}[Y] = 23$ et $\text{Var}(Y) = 8$
- C) $\mathbb{E}[Y] = 23$ et $\text{Var}(Y) = 16$
- D) $\mathbb{E}[Y] = 20$ et $\text{Var}(Y) = 4$
- E) aucune des réponses proposées

30. Si $X \sim \mathcal{N}(5, 9)$, alors $\mathbb{P}(X \leq 8)$ vaut approximativement :

- A) 0.16
- B) 0.50
- C) 0.68
- D) 0.84
- E) aucune des réponses proposées

31. Si $X \sim \mathcal{N}(100, 25)$, un intervalle contenant environ 95% de la distribution est :

- A) $[95, 105]$
- B) $[90.2, 109.8]$
- C) $[75, 125]$
- D) $[100, 125]$
- E) aucune des réponses proposées

32. Si X et Y sont indépendantes, avec $\text{Var}(X) = 4$ et $\text{Var}(Y) = 1$, alors

$$\text{Var}(2X - 3Y)$$

vaut :

- A) 5
- B) 7
- C) 25
- D) 49
- E) aucune des réponses proposées

33. Si $\text{Cov}(X, Y) = 3$, alors

$$\text{Cov}(2X + 3, -Y + 1)$$

vaut :

- A) -6
- B) -3
- C) 3
- D) 6
- E) aucune des réponses proposées

34. Si $X \sim \text{Binomial}(10, 0.2)$, alors

$$\mathbb{P}(X = 0)$$

vaut :

- A) 0.2^{10}
- B) $1 - 0.2^{10}$
- C) 0.8^{10}
- D) 10×0.2
- E) aucune des réponses proposées

35. Si $X \sim \text{Binomial}(n, p)$, alors la proportion X/n vérifie :

- A) $\mathbb{E}[X/n] = np$
- B) $\mathbb{E}[X/n] = p$ et $\text{Var}(X/n) = p(1-p)/n$
- C) $\mathbb{E}[X/n] = p/n$ et $\text{Var}(X/n) = p(1-p)$
- D) $\mathbb{E}[X/n] = 0$
- E) aucune des réponses proposées

36. Si $X \sim \text{Poisson}(2)$, alors

$$\mathbb{P}(X = 0)$$

vaut :

- A) e^{-2}
- B) $2e^{-2}$
- C) $1 - e^{-2}$
- D) 0
- E) aucune des réponses proposées

37. Si $X \sim \text{Poisson}(3)$ et $Y \sim \text{Poisson}(4)$ sont indépendantes, alors

$$\mathbb{P}(X + Y = 0)$$

vaut :

- A) e^{-3}
- B) e^{-4}
- C) e^{-12}
- D) e^{-7}
- E) aucune des réponses proposées

38. Si $X_1, \dots, X_n$ sont i.i.d. de loi normale $\mathcal{N}(\mu, \sigma^2)$, avec σ^2 connue, l'estimateur du maximum de vraisemblance de μ est :

- A) X_1
- B) σ^2
- C) $\bar{X}$
- D) $n\bar{X}$
- E) aucune des réponses proposées

39. Un p -value est :

- A) la probabilité que l'hypothèse nulle soit vraie

- B) la probabilité, sous l'hypothèse nulle, d'obtenir une statistique au moins aussi extrême que celle observée
- C) la probabilité que l'hypothèse alternative soit fausse
- D) toujours égal au risque de première espèce
- E) aucune des réponses proposées

40. Le risque de première espèce d'un test est :

- A) la probabilité de ne pas rejeter H_0 lorsqu'elle est fausse
- B) la probabilité de rejeter H_0 lorsqu'elle est fausse
- C) la probabilité de rejeter H_0 lorsqu'elle est vraie
- D) la probabilité que le modèle soit linéaire
- E) aucune des réponses proposées

41. On considère la fonction

$$f(x) = 3x^2 + 12x + 5.$$

Le minimum est atteint en :

- A) $x = -4$
- B) $x = -2$
- C) $x = 0$
- D) $x = 2$
- E) aucune des réponses proposées

42. On considère la fonction

$$f(x, y) = (x + 1)^2 + 4(y - 3)^2.$$

Le minimum est atteint en :

- A) $(1, 3)$
- B) $(-1, 3)$
- C) $(1, -3)$
- D) $(-1, -3)$
- E) aucune des réponses proposées

43. On considère

$$f(x, y) = x^2 + xy + y^2.$$

Le gradient de f au point $(1, 2)$ est :

- A) $(1, 2)$
- B) $(2, 4)$
- C) $(4, 5)$
- D) $(5, 4)$
- E) aucune des réponses proposées

44. On considère

$$f(x, y) = x^2 + xy + 2y^2.$$

La matrice hessienne de f est :

- A) $\begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$
- B) $\begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}$

C) $\begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$

D) $\begin{pmatrix} x & y \\ y & x \end{pmatrix}$

E) aucune des réponses proposées

45. Si A est une matrice $n \times p$ et B une matrice $p \times q$, alors AB est :

A) une matrice $n \times q$

B) une matrice $p \times p$

C) une matrice $q \times n$

D) un scalaire

E) aucune des réponses proposées

46. On considère le système

$$\begin{cases} a + b = 4, \\ a - b = 2. \end{cases}$$

La solution est :

A) $(a, b) = (1, 3)$

B) $(a, b) = (2, 2)$

C) $(a, b) = (3, 1)$

D) $(a, b) = (4, 2)$

E) aucune des réponses proposées

47. Lequel des vecteurs suivants est orthogonal à

$$\vec{a} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}?$$

A) $\begin{pmatrix} 1 \\ 2 \end{pmatrix}$

B) $\begin{pmatrix} 2 \\ 1 \end{pmatrix}$

C) $\begin{pmatrix} 1 \\ -2 \end{pmatrix}$

D) $\begin{pmatrix} 2 \\ -1 \end{pmatrix}$

E) aucune des réponses proposées

48. La norme euclidienne du vecteur

$$\vec{a} = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$$

est :

A) 1

B) 5

C) 7

D) 25

E) aucune des réponses proposées

49. La projection orthogonale du vecteur $(2, 0)$ sur la droite engendrée par $(1, 1)$ est :

- A) $(2, 0)$
- B) $(0, 2)$
- C) $(1, 1)$
- D) $(0, 0)$
- E) aucune des réponses proposées

50. Si $\text{Var}(X) = 9$ et $\text{Var}(Y) = 4$, alors

$$\text{Cov}(X + Y, X - Y)$$

vaut :

- A) 5
- B) 13
- C) 36
- D) 0
- E) aucune des réponses proposées

51. Si $\mathbb{E}[X] = 1$ et $\mathbb{E}[Y] = 4$, alors

$$\mathbb{E}[2X - 3Y]$$

vaut :

- A) -10
- B) -5
- C) 2
- D) 14
- E) aucune des réponses proposées

52. Si $X \sim \mathcal{N}(50, 100)$, alors

$$\mathbb{P}(X \leq 60)$$

vaut approximativement :

- A) 0.16
- B) 0.50
- C) 0.84
- D) 0.975
- E) aucune des réponses proposées

53. Si $Z \sim \mathcal{N}(0, 1)$, alors

$$\mathbb{P}(-1.96 \leq Z \leq 1.96)$$

vaut approximativement :

- A) 0.50
- B) 0.68
- C) 0.90
- D) 0.95
- E) aucune des réponses proposées

54. Si $X \sim \text{Binomial}(5, 0.5)$, alors

$$\mathbb{P}(X = 2)$$

vaut :

- A) $5/32$
- B) $10/32$
- C) $15/32$
- D) $1/2$
- E) aucune des réponses proposées

55. Si $X \sim \text{Bernoulli}(0.3)$, alors $\text{Var}(X)$ vaut :

- A) 0.09
- B) 0.21
- C) 0.30
- D) 0.70
- E) aucune des réponses proposées

56. Si $X \sim \text{Poisson}(4)$, alors

$$\mathbb{P}(X = 1)$$

vaut :

- A) e^{-4}
- B) $4e^{-4}$
- C) $16e^{-4}$
- D) $1 - e^{-4}$
- E) aucune des réponses proposées

57. Si A et B sont deux événements, avec $\mathbb{P}(B) > 0$, alors

$$\mathbb{P}(A|B)$$

est égale à :

- A) $\mathbb{P}(A)\mathbb{P}(B)$
- B) $\mathbb{P}(A \cap B)/\mathbb{P}(B)$
- C) $\mathbb{P}(A)/\mathbb{P}(B)$
- D) $\mathbb{P}(A \cup B)$
- E) aucune des réponses proposées

58. Si A et B sont indépendants, avec $\mathbb{P}(A) = 0.2$ et $\mathbb{P}(B) = 0.5$, alors

$$\mathbb{P}(A \cap B)$$

vaut :

- A) 0.1
- B) 0.2
- C) 0.5
- D) 0.7
- E) aucune des réponses proposées

59. Si $X_1, \dots, X_{100}$ sont i.i.d. de variance 25, alors

$$\text{Var}(\bar{X})$$

vaut :

- A) 25

- B) 5
- C) 0.25
- D) 0.05
- E) aucune des réponses proposées

60. Sous les hypothèses usuelles du théorème central limite, si $X_1, \dots, X_n$ sont i.i.d. de moyenne μ et variance σ^2 , alors

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$$

converge en loi vers :

- A) une loi normale centrée réduite
- B) une loi de Poisson
- C) une loi binomiale
- D) une constante égale à μ
- E) aucune des réponses proposées

61. Un estimateur $\hat{\theta}$ est dit sans biais pour θ si :

- A) $\hat{\theta} = \theta$ pour tous les échantillons
- B) $\mathbb{E}[\hat{\theta}] = \theta$
- C) $\text{Var}(\hat{\theta}) = 0$
- D) $\hat{\theta}$ est toujours positif
- E) aucune des réponses proposées

62. On observe quatre variables de Bernoulli :

1, 0, 1, 1.

L'estimateur du maximum de vraisemblance de p est :

- A) 1/4
- B) 1/2
- C) 3/4
- D) 1
- E) aucune des réponses proposées

63. Si $\bar{X} = 12$, $\sigma = 4$ connue, et $n = 16$, un intervalle de confiance approximatif à 95% pour μ est :

- A) $12 \pm 1.96 \times 4$
- B) $12 \pm 1.96 \times 4/16$
- C) $12 \pm 1.96 \times 4/\sqrt{16}$
- D) $12 \pm 4/\sqrt{16}$
- E) aucune des réponses proposées

64. Pour tester $H_0 : \mu = \mu_0$ avec un échantillon de moyenne $\bar{X}$, écart-type empirique s et taille n , une statistique usuelle est :

- A) $\frac{\bar{X} - \mu_0}{s/\sqrt{n}}$
- B) $\frac{s - \mu_0}{\bar{X}}$
- C) $\frac{\bar{X}}{n}$

- D) $\bar{X} + s$
- E) aucune des réponses proposées

65. Le risque de deuxième espèce d'un test est :

- A) la probabilité de rejeter H_0 lorsqu'elle est vraie
- B) la probabilité de ne pas rejeter H_0 lorsqu'elle est fausse
- C) la probabilité que H_0 soit vraie sachant qu'on l'a rejetée
- D) la probabilité que la statistique de test soit négative
- E) aucune des réponses proposées

66. On considère la fonction

$$f(x) = (x - 3)^2 + 2.$$

Le minimum est atteint en :

- A) $x = -3$
- B) $x = 3$
- C) $x = 2$
- D) $x = 6$
- E) aucune des réponses proposées

67. On considère la fonction

$$f(x, y) = x^2 + y^2 - 2x + 4y + 7.$$

Le minimum est atteint en :

- A) $(0, 0)$
- B) $(-1, 2)$
- C) $(1, -2)$
- D) $(2, -4)$
- E) aucune des réponses proposées

68. On considère

$$f(x, y) = x^2 + 3xy + y^2.$$

Le gradient de f au point $(1, 1)$ est :

- A) $(2, 2)$
- B) $(5, 5)$
- C) $(3, 3)$
- D) $(1, 1)$
- E) aucune des réponses proposées

69. On considère

$$f(x, y) = 2x^2 + xy + 3y^2.$$

La matrice hessienne de f est :

- A) $\begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$
- B) $\begin{pmatrix} 4 & 1 \\ 1 & 6 \end{pmatrix}$
- C) $\begin{pmatrix} 4 & 0 \\ 0 & 6 \end{pmatrix}$

D) $\begin{pmatrix} x & y \\ y & x \end{pmatrix}$

E) aucune des réponses proposées

70. Si A est une matrice 4×3 et B une matrice 3×2 , alors AB est :

A) une matrice 3×3

B) une matrice 2×4

C) une matrice 4×3

D) une matrice 4×2

E) aucune des réponses proposées

71. On considère la matrice

$$A = \begin{pmatrix} 2 & 1 \\ 4 & 2 \end{pmatrix}.$$

Que peut-on dire de ses colonnes ?

A) elles sont orthogonales

B) elles sont identiques

C) elles sont linéairement dépendantes

D) elles sont toutes deux nulles

E) aucune des réponses proposées

72. On considère les vecteurs

$$\vec{a} = \begin{pmatrix} 1 \\ -2 \\ 2 \end{pmatrix}, \quad \vec{b} = \begin{pmatrix} 3 \\ 1 \\ 4 \end{pmatrix}.$$

Que vaut $\vec{a}^\top \vec{b}$?

A) 0

B) 3

C) 6

D) 9

E) aucune des réponses proposées

73. La projection orthogonale du vecteur $(4, 2)$ sur l'axe horizontal est :

A) $(0, 2)$

B) $(4, 0)$

C) $(2, 4)$

D) $(0, 0)$

E) aucune des réponses proposées

74. Le vecteur centré associé à

$$y = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

est :

A) $(1, 2, 3)$

B) $(0, 1, 2)$

C) $(-1, 0, 1)$

- D) $(1, 0, -1)$
- E) aucune des réponses proposées

75. Si $\text{Var}(X) = 4$, alors

$$\text{Var}(3 - 2X)$$

vaut :

- A) 4
- B) 8
- C) 16
- D) 19
- E) aucune des réponses proposées

76. Si $\text{Var}(X) = 4$ et $\text{Cov}(X, Y) = 1$, alors

$$\text{Cov}(X + Y, X)$$

vaut :

- A) 3
- B) 5
- C) 8
- D) 1
- E) aucune des réponses proposées

77. Si $X \sim \mathcal{N}(20, 16)$, alors

$$\mathbb{P}(X > 24)$$

vaut approximativement :

- A) 0.16
- B) 0.50
- C) 0.84
- D) 0.975
- E) aucune des réponses proposées

78. Si $X \sim \mathcal{N}(1, 4)$ et $Y \sim \mathcal{N}(2, 9)$ sont indépendantes, alors $X - Y$ suit :

- A) $\mathcal{N}(3, 13)$
- B) $\mathcal{N}(-1, 5)$
- C) $\mathcal{N}(-1, 13)$
- D) $\mathcal{N}(1, 13)$
- E) aucune des réponses proposées

79. Si $X \sim \text{Bernoulli}(0.3)$, alors

$$\mathbb{P}(X = 0)$$

vaut :

- A) 0.3
- B) 0.09
- C) 0.21
- D) 0.7
- E) aucune des réponses proposées

80. Si $X \sim \text{Binomial}(4, 0.25)$, alors

$$\mathbb{P}(X = 1)$$

vaut :

- A) $1/4$
- B) $9/64$
- C) $27/64$
- D) $1/64$
- E) aucune des réponses proposées

81. Si $X \sim \text{Poisson}(3)$, alors

$$\mathbb{P}(X = 2)$$

vaut :

- A) $3e^{-3}$
- B) $\frac{9}{2}e^{-3}$
- C) $9e^{-3}$
- D) $1 - e^{-3}$
- E) aucune des réponses proposées

82. Si $X \sim \text{Poisson}(2)$ et $Y \sim \text{Poisson}(5)$ sont indépendantes, alors $X + Y$ suit :

- A) une loi de Poisson de paramètre 2
- B) une loi de Poisson de paramètre 5
- C) une loi de Poisson de paramètre 10
- D) une loi de Poisson de paramètre 7
- E) aucune des réponses proposées

83. Une loi $\text{Binomial}(100, 0.02)$ peut être approximée par :

- A) une loi de Poisson de paramètre 2
- B) une loi de Poisson de paramètre 100
- C) une loi normale centrée réduite sans transformation
- D) une loi Bernoulli de paramètre 0.02
- E) aucune des réponses proposées

84. On suppose

$$\mathbb{P}(A) = 0.1, \quad \mathbb{P}(B|A) = 0.8, \quad \mathbb{P}(B|A^c) = 0.2.$$

Alors $\mathbb{P}(A|B)$ vaut :

- A) 0.08
- B) $4/13$
- C) 0.8
- D) $1/2$
- E) aucune des réponses proposées

85. Si A est un événement, alors

$$\mathbb{E}[\mathbf{1}_A]$$

vaut :

- A) 0

- B) 1
- C) $\mathbb{P}(A)$
- D) $\mathbb{E}(A)$
- E) aucune des réponses proposées

86. Si $X_1, \dots, X_{36}$ sont i.i.d. d'écart-type $\sigma = 6$, alors l'écart-type de $\bar{X}$ vaut :

- A) 1
- B) 6
- C) 36
- D) $1/6$
- E) aucune des réponses proposées

87. On observe $\bar{X} = 10$, $s = 2$ et $n = 25$. Pour tester $H_0 : \mu = 9$, la statistique

$$\frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

vaut :

- A) 0.4
- B) 1
- C) 2
- D) 2.5
- E) aucune des réponses proposées

88. On observe $\bar{X} = 50$, avec $\sigma = 10$ connu et $n = 100$. Un intervalle de confiance approximatif à 95% pour μ est :

- A) 50 ± 10
- B) $50 \pm 1.96 \times 10$
- C) 50 ± 1.96
- D) 50 ± 0.196
- E) aucune des réponses proposées

89. Pour un test statistique, si la p -value vaut 0.03, alors au seuil de 5% :

- A) on ne rejette jamais H_0
- B) on rejette H_0
- C) on accepte définitivement H_0
- D) le test est impossible à interpréter
- E) aucune des réponses proposées

Partie 2 — Modèle linéaire estimé par moindres carrés ordinaires

90. On estime une régression linéaire simple

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $\hat{\beta}_0 = 2$ et $\hat{\beta}_1 = 3$. Quelle est la valeur prédite pour une observation telle que $x = 4$?

- A) 5
- B) 8

- C) 12
- D) 14
- E) aucune des réponses proposées

91. On estime deux modèles :

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

et

$$y_i = \gamma_0 + \gamma_1(x_i - \bar{x}) + u_i.$$

Quelle affirmation est vraie ?

- A) $\gamma_1 = 0$ car la variable est centrée.
- B) $\gamma_1 = \beta_1$.
- C) $\gamma_0 = \beta_0$.
- D) Le R^2 du second modèle est toujours plus grand.
- E) Aucune des réponses proposées.

92. Dans le modèle

$$\mathbb{E}[Y \mid x, \text{zone}] = \beta_0 + \beta_1 x + \beta_2 \mathbf{1}_{\{\text{zone}=B\}},$$

la zone A est la référence. Comment interpréter $\hat{\beta}_2 = 3.2$?

- A) La moyenne de Y en zone B vaut 3.2.
- B) À x fixé, la moyenne de Y en zone B est supérieure de 3.2 à celle en zone A .
- C) Quand x augmente d'une unité, Y augmente de 3.2 en zone B .
- D) La zone B explique 3.2% de la variance.
- E) Aucune des réponses proposées.

93. On estime

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 z_i + \beta_3 x_i z_i + \varepsilon_i,$$

où $z_i \in \{0, 1\}$. Quel est l'effet marginal de x lorsque $z = 1$?

- A) β_1 .
- B) β_2 .
- C) $\beta_1 + \beta_3$.
- D) $\beta_2 + \beta_3$.
- E) Aucune des réponses proposées.

94. Le vrai modèle est

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon,$$

avec $\beta_2 > 0$ et $\text{Cov}(X_1, X_2) > 0$. Si l'on estime seulement Y sur X_1 , que peut-on dire du coefficient de X_1 ?

- A) Il est toujours égal à β_1 .
- B) Il est biaisé vers le bas.
- C) Il est biaisé vers le haut.
- D) Il vaut nécessairement zéro.
- E) Aucune des réponses proposées.

95. Lorsqu'on ajoute une variable explicative dans une régression linéaire avec constante :

- A) le R^2 ne peut pas diminuer.
- B) le R^2 ajusté ne peut pas diminuer.

- C) le R^2 et le R^2 ajusté augmentent toujours.
- D) l'écart-type résiduel augmente toujours.
- E) Aucune des réponses proposées.

96. Une observation a un fort levier, ou *high leverage*, si :

- A) son résidu est très grand.
- B) sa valeur de Y est extrême.
- C) ses variables explicatives sont atypiques.
- D) elle est nécessairement mal prédite.
- E) Aucune des réponses proposées.

97. En présence d'hétéroscédasticité, si $\mathbb{E}[\varepsilon | X] = 0$, les estimateurs MCO sont :

- A) nécessairement biaisés.
- B) encore centrés, mais les écarts-types usuels peuvent être incorrects.
- C) inutilisables car le R^2 n'a plus de sens.
- D) identiques aux estimateurs de moindres carrés pondérés.
- E) Aucune des réponses proposées.

98. Dans un modèle

$$\log(Y) = \beta_0 + \beta_1 x + \varepsilon,$$

on obtient $\hat{\beta}_1 = 0.04$. Une augmentation d'une unité de x est associée approximativement à :

- A) une hausse de Y de 0.04 unité.
- B) une hausse de Y de 4%.
- C) une baisse de Y de 4%.
- D) une hausse de $\log(Y)$ de 4 unités.
- E) Aucune des réponses proposées.

99. L'écart-type résiduel d'un modèle linéaire vaut 5. Cela signifie :

- A) les erreurs de prédiction valent toutes exactement 5.
- B) la moyenne des résidus vaut 5.
- C) les résidus ont une dispersion typique d'environ 5 unités de Y .
- D) le R^2 vaut 0.5.
- E) Aucune des réponses proposées.

100. Pour une même valeur x_0 , l'intervalle de prédiction d'une nouvelle observation est généralement :

- A) plus étroit que l'intervalle de confiance de $\mathbb{E}[Y | X = x_0]$.
- B) de même largeur.
- C) plus large.
- D) toujours centré en zéro.
- E) Aucune des réponses proposées.

101. On estime un modèle linéaire avec deux variables X_1 et X_2 . Si X_1 et X_2 sont très corrélées, alors :

- A) les estimateurs des coefficients sont nécessairement biaisés.
- B) les écarts-types des coefficients peuvent être élevés.
- C) le R^2 devient nécessairement négatif.
- D) les résidus ont nécessairement une moyenne non nulle.

E) Aucune des réponses proposées.

102. On compare deux modèles emboîtés, $\mathcal{M}_0$ et $\mathcal{M}_1$, où $\mathcal{M}_0$ est obtenu en imposant une restriction linéaire à $\mathcal{M}_1$. Le test usuel de comparaison des deux modèles est :

A) un test de Student sur la constante uniquement.

B) un test de Fisher.

C) un test de Kolmogorov–Smirnov.

D) un test de normalité des résidus.

E) Aucune des réponses proposées.

103. On utilise la base `stackloss`, disponible dans le package R `datasets`. Elle contient 21 observations et 4 variables : `Air.Flow`, `Water.Temp`, `Acid.Conc` et `stack.loss`. On estime le modèle suivant :

```
data(stackloss)
reg <- lm(stack.loss ~ Air.Flow + Water.Temp + Acid.Conc,
          data = stackloss)
summary(reg)
```

La sortie obtenue est partiellement masquée :

```
Call:
lm(formula = stack.loss ~ Air.Flow + Water.Temp + Acid.Conc,
    data = stackloss)

Residuals:
    Min       1Q   Median       3Q      Max
-7.237  -1.712  -0.456   2.361   5.698

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -39.9197    11.8960  -3.356  0.00375 **
Air.Flow       0.7156     0.1349   ???    0.000058 ***
Water.Temp     1.2953     0.3680   3.520  0.00263 **
Acid.Conc     -0.1521     0.1563  -0.973  0.34405

Residual standard error: 3.243 on 17 degrees of freedom
Multiple R-squared:  0.9136, Adjusted R-squared:  ???
F-statistic: 59.90 on 3 and 17 DF, p-value: 3.02e-09
```

Quelle est environ la valeur masquée du t -statistic de `Air.Flow`?

A) 0.19.

B) 1.35.

C) 5.31.

D) 9.14.

E) Aucune des réponses proposées.

104. Au seuil de 5%, quelle variable n'est pas significative dans ce modèle?

A) `Air.Flow`.

B) `Water.Temp`.

C) `Acid.Conc`.

D) Toutes les variables sont significatives.

E) Aucune des réponses proposées.

105. Combien d'observations ont été utilisées dans la régression précédente ?

- A) 17.
- B) 18.
- C) 20.
- D) 21.
- E) On ne peut pas savoir.

106. Quelle est l'interprétation de $\hat{\beta}_{\text{Air.Flow}} = 0.7156$?

- A) Une hausse d'une unité de **Air.Flow** augmente la valeur prédite de **stack.loss** d'environ 0.716, toutes choses égales par ailleurs.
- B) Une hausse d'une unité de **Air.Flow** multiplie la valeur prédite par 0.716.
- C) Une hausse d'une unité de **Air.Flow** augmente la probabilité de **stack.loss** de 0.716.
- D) **Air.Flow** explique 71.56% de la variance.
- E) Aucune des réponses proposées.

107. Une approximation de l'intervalle de confiance à 95% pour le coefficient de **Air.Flow** est :

- A) [0.01; 0.28].
- B) [-0.15; 0.72].
- C) [0.43; 1.00].
- D) [1.00; 1.43].
- E) Aucune des réponses proposées.

108. Pour une observation avec

$$\text{Air.Flow} = 60, \quad \text{Water.Temp} = 20, \quad \text{Acid.Conc} = 85,$$

la prédiction vaut environ :

- A) 4.1.
- B) 16.0.
- C) 28.4.
- D) 60.0.
- E) Aucune des réponses proposées.

109. On estime aussi le modèle réduit :

```
reg0 <- lm(stack.loss ~ Air.Flow + Water.Temp, data = stackloss)
```

On obtient :

```
RSS(reg0) = 188.80  
RSS(reg) = 178.83
```

Le test de comparaison entre **reg0** et **reg** revient ici à tester :

- A) si **Air.Flow** est utile.
- B) si **Water.Temp** est utile.
- C) si **Acid.Conc** apporte quelque chose en plus des deux autres variables.
- D) si la constante est nulle.
- E) Aucune des réponses proposées.

110. Sachant que la p -value associée à **Acid.Conc** vaut 0.344, que conclure au seuil de 5% ?

- A) On rejette le modèle complet.
- B) On garde nécessairement `Acid.Conc` car le R^2 est élevé.
- C) On n'a pas d'évidence statistique forte que `Acid.Conc` améliore le modèle une fois `Air.Flow` et `Water.Temp` inclus.
- D) Le modèle linéaire est impossible car il y a 21 observations.
- E) Aucune des réponses proposées.

111. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On remplace ensuite X_i par $Z_i = 10X_i$. Quel est le lien entre le coefficient de Z et celui de X ?

- A) Le coefficient de Z vaut $10\hat{\beta}_1$
- B) Le coefficient de Z vaut $\hat{\beta}_1/10$
- C) Le coefficient de Z vaut $\hat{\beta}_1$
- D) Le coefficient de Z vaut $\hat{\beta}_1^2$
- E) aucune des réponses proposées

112. Dans une régression linéaire avec constante, la somme des résidus vaut :

- A) toujours 1
- B) toujours 0
- C) toujours égale au R^2
- D) toujours égale à la variance résiduelle
- E) aucune des réponses proposées

113. On estime un modèle linéaire simple avec constante. La droite ajustée passe nécessairement par :

- A) le point $(0, 0)$
- B) le point $(\bar{X}, \bar{Y})$
- C) le point $(\hat{\beta}_0, \hat{\beta}_1)$
- D) l'observation ayant le plus grand levier
- E) aucune des réponses proposées

114. Dans un modèle linéaire, une variable explicative qualitative à 4 modalités est introduite avec une constante. Combien de variables indicatrices doit-on inclure ?

- A) 1
- B) 2
- C) 3
- D) 4
- E) aucune des réponses proposées

115. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $\hat{\beta}_1 = 2$ et $\widehat{\text{se}}(\hat{\beta}_1) = 0.5$. Quelle est la statistique de test de $H_0 : \beta_1 = 0$?

- A) 0.25
- B) 1
- C) 2
- D) 4
- E) aucune des réponses proposées

116. Dans un modèle linéaire, un intervalle de confiance à 95% pour β_1 est donné approximativement par :

- A) $\hat{\beta}_1 \pm 1.96 \widehat{\text{se}}(\hat{\beta}_1)$
- B) $\hat{\beta}_1 \pm R^2$
- C) $\hat{\beta}_1 \pm \hat{\sigma}^2$
- D) $\hat{\beta}_1 / \widehat{\text{se}}(\hat{\beta}_1)$
- E) aucune des réponses proposées

117. Si une variable explicative est presque parfaitement corrélée avec une autre variable explicative, on parle généralement :

- A) d'hétéroscédasticité
- B) d'autocorrélation
- C) de multicollinéarité
- D) d'endogénéité parfaite
- E) aucune des réponses proposées

118. Une forte multicollinéarité a généralement pour conséquence :

- A) de rendre les estimateurs MCO nécessairement biaisés
- B) d'augmenter l'incertitude sur certains coefficients estimés
- C) de rendre le R^2 toujours nul
- D) de supprimer automatiquement la constante
- E) aucune des réponses proposées

119. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Si $\hat{\beta}_1 < 0$, alors :

- A) X et Y sont positivement corrélés
- B) X et Y sont négativement corrélés
- C) le modèle est nécessairement faux
- D) le R^2 est nécessairement négatif
- E) aucune des réponses proposées

120. Dans une régression linéaire avec constante, le coefficient de détermination R^2 mesure :

- A) la proportion de variance de Y expliquée par le modèle
- B) la moyenne des résidus
- C) la variance de X
- D) la probabilité que le modèle soit vrai
- E) aucune des réponses proposées

121. On compare deux modèles emboîtés. Le modèle complet contient toutes les variables du modèle réduit, plus une variable supplémentaire. Le test de Fisher de comparaison teste :

- A) si la variable supplémentaire améliore significativement l'ajustement
- B) si les résidus sont normaux
- C) si le R^2 est supérieur à 1
- D) si toutes les observations sont indépendantes
- E) aucune des réponses proposées

122. On estime un modèle linéaire avec $n = 100$ observations et $p = 4$ paramètres, constante incluse. Le nombre de degrés de liberté résiduels est :

- A) 100
- B) 99
- C) 96
- D) 4
- E) aucune des réponses proposées

123. Dans un graphique résidus contre valeurs ajustées, un motif en forme d'entonnoir suggère souvent :

- A) une hétéroscédasticité
- B) une absence totale de relation entre X et Y
- C) une colinéarité parfaite
- D) une variable qualitative mal codée
- E) aucune des réponses proposées

124. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Si l'on ajoute une constante c à toutes les valeurs de Y , que devient le coefficient de pente ?

- A) Il augmente de c
- B) Il diminue de c
- C) Il est inchangé
- D) Il est multiplié par c
- E) aucune des réponses proposées

125. Dans un modèle linéaire, une observation influente est une observation :

- A) dont la suppression modifie fortement les coefficients estimés
- B) dont le résidu est forcément nul
- C) dont la valeur de Y est toujours moyenne
- D) dont le poids statistique est toujours égal à zéro
- E) aucune des réponses proposées

126. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $\hat{\beta}_0 = 3$ et $\hat{\beta}_1 = 2$. Quelle est la valeur prédite pour $X = 4$?

- A) 5
- B) 8
- C) 11
- D) 14
- E) aucune des réponses proposées

127. Le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$$

est :

- A) non linéaire en les paramètres
- B) linéaire en les paramètres

- C) impossible à estimer par moindres carrés
- D) un modèle logistique
- E) aucune des réponses proposées

128. Dans le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i,$$

l'effet marginal de X sur l'espérance conditionnelle de Y est :

- A) β_1
- B) β_2
- C) $\beta_1 + \beta_2$
- D) $\beta_1 + 2\beta_2 X$
- E) aucune des réponses proposées

129. On estime un modèle avec une variable qualitative **region** ayant trois modalités : A, B, C. La modalité A est la référence. Si le coefficient associé à **regionB** vaut -2 , alors :

- A) la moyenne prédite en région B est inférieure de 2 à celle de la région A, toutes choses égales par ailleurs
- B) la moyenne prédite en région B est égale à -2
- C) la région B est supprimée du modèle
- D) la variable **region** n'est pas significative
- E) aucune des réponses proposées

130. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $R^2 = 0.64$. Dans une régression simple avec constante, la corrélation empirique entre X et Y vaut :

- A) nécessairement 0.64
- B) nécessairement 0.80
- C) nécessairement -0.80
- D) soit 0.80, soit -0.80 , selon le signe de $\hat{\beta}_1$
- E) aucune des réponses proposées

131. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On remplace ensuite X_i par $Z_i = 10X_i$. Quel est le lien entre le coefficient de Z et celui de X ?

- A) Le coefficient de Z vaut $10\hat{\beta}_1$
- B) Le coefficient de Z vaut $\hat{\beta}_1/10$
- C) Le coefficient de Z vaut $\hat{\beta}_1$
- D) Le coefficient de Z vaut $\hat{\beta}_1^2$
- E) aucune des réponses proposées

132. Dans une régression linéaire avec constante, la somme des résidus vaut :

- A) toujours 1
- B) toujours 0
- C) toujours égale au R^2
- D) toujours égale à la variance résiduelle
- E) aucune des réponses proposées

133. On estime un modèle linéaire simple avec constante. La droite ajustée passe nécessairement par :

- A) le point $(0, 0)$
- B) le point $(\bar{X}, \bar{Y})$
- C) le point $(\hat{\beta}_0, \hat{\beta}_1)$
- D) l'observation ayant le plus grand levier
- E) aucune des réponses proposées

134. Dans un modèle linéaire, une variable explicative qualitative à 4 modalités est introduite avec une constante. Combien de variables indicatrices doit-on inclure ?

- A) 1
- B) 2
- C) 3
- D) 4
- E) aucune des réponses proposées

135. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $\hat{\beta}_1 = 2$ et $\widehat{\text{se}}(\hat{\beta}_1) = 0.5$. Quelle est la statistique de test de $H_0 : \beta_1 = 0$?

- A) 0.25
- B) 1
- C) 2
- D) 4
- E) aucune des réponses proposées

136. Dans un modèle linéaire, un intervalle de confiance à 95% pour β_1 est donné approximativement par :

- A) $\hat{\beta}_1 \pm 1.96 \widehat{\text{se}}(\hat{\beta}_1)$
- B) $\hat{\beta}_1 \pm R^2$
- C) $\hat{\beta}_1 \pm \hat{\sigma}^2$
- D) $\hat{\beta}_1 / \widehat{\text{se}}(\hat{\beta}_1)$
- E) aucune des réponses proposées

137. Si une variable explicative est presque parfaitement corrélée avec une autre variable explicative, on parle généralement :

- A) d'hétéroscédasticité
- B) d'autocorrélation
- C) de multicollinéarité
- D) d'endogénéité parfaite
- E) aucune des réponses proposées

138. Une forte multicollinéarité a généralement pour conséquence :

- A) de rendre les estimateurs MCO nécessairement biaisés
- B) d'augmenter l'incertitude sur certains coefficients estimés
- C) de rendre le R^2 toujours nul
- D) de supprimer automatiquement la constante
- E) aucune des réponses proposées

139. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Si $\hat{\beta}_1 < 0$, alors :

- A) X et Y sont positivement corrélés
- B) X et Y sont négativement corrélés
- C) le modèle est nécessairement faux
- D) le R^2 est nécessairement négatif
- E) aucune des réponses proposées

140. Dans une régression linéaire avec constante, le coefficient de détermination R^2 mesure :

- A) la proportion de variance de Y expliquée par le modèle
- B) la moyenne des résidus
- C) la variance de X
- D) la probabilité que le modèle soit vrai
- E) aucune des réponses proposées

141. On compare deux modèles emboîtés. Le modèle complet contient toutes les variables du modèle réduit, plus une variable supplémentaire. Le test de Fisher de comparaison teste :

- A) si la variable supplémentaire améliore significativement l'ajustement
- B) si les résidus sont normaux
- C) si le R^2 est supérieur à 1
- D) si toutes les observations sont indépendantes
- E) aucune des réponses proposées

142. On estime un modèle linéaire avec $n = 100$ observations et $p = 4$ paramètres, constante incluse. Le nombre de degrés de liberté résiduels est :

- A) 100
- B) 99
- C) 96
- D) 4
- E) aucune des réponses proposées

143. Dans un graphique résidus contre valeurs ajustées, un motif en forme d'entonnoir suggère souvent :

- A) une hétéroscédasticité
- B) une absence totale de relation entre X et Y
- C) une colinéarité parfaite
- D) une variable qualitative mal codée
- E) aucune des réponses proposées

144. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Si l'on ajoute une constante c à toutes les valeurs de Y , que devient le coefficient de pente ?

- A) Il augmente de c
- B) Il diminue de c
- C) Il est inchangé

- D) Il est multiplié par c
- E) aucune des réponses proposées

145. Dans un modèle linéaire, une observation influente est une observation :

- A) dont la suppression modifie fortement les coefficients estimés
- B) dont le résidu est forcément nul
- C) dont la valeur de Y est toujours moyenne
- D) dont le poids statistique est toujours égal à zéro
- E) aucune des réponses proposées

146. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $\hat{\beta}_0 = 3$ et $\hat{\beta}_1 = 2$. Quelle est la valeur prédite pour $X = 4$?

- A) 5
- B) 8
- C) 11
- D) 14
- E) aucune des réponses proposées

147. Le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i$$

est :

- A) non linéaire en les paramètres
- B) linéaire en les paramètres
- C) impossible à estimer par moindres carrés
- D) un modèle logistique
- E) aucune des réponses proposées

148. Dans le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \varepsilon_i,$$

l'effet marginal de X sur l'espérance conditionnelle de Y est :

- A) β_1
- B) β_2
- C) $\beta_1 + \beta_2$
- D) $\beta_1 + 2\beta_2 X$
- E) aucune des réponses proposées

149. On estime un modèle avec une variable qualitative **region** ayant trois modalités : A, B, C. La modalité A est la référence. Si le coefficient associé à **regionB** vaut -2 , alors :

- A) la moyenne prédite en région B est inférieure de 2 à celle de la région A, toutes choses égales par ailleurs
- B) la moyenne prédite en région B est égale à -2
- C) la région B est supprimée du modèle
- D) la variable **region** n'est pas significative
- E) aucune des réponses proposées

150. On estime le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On obtient $R^2 = 0.64$. Dans une régression simple avec constante, la corrélation empirique entre X et Y vaut :

- A) nécessairement 0.64
- B) nécessairement 0.80
- C) nécessairement -0.80
- D) soit 0.80, soit -0.80 , selon le signe de $\hat{\beta}_1$
- E) aucune des réponses proposées

151. On considère le modèle linéaire multiple

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

où $\mathbf{X}$ est une matrice $n \times p$. Si $\mathbf{X}^\top \mathbf{X}$ est inversible, l'estimateur des moindres carrés ordinaires est :

- A) $\hat{\boldsymbol{\beta}} = \mathbf{X}\mathbf{Y}$
- B) $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$
- C) $\hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{Y}$
- D) $\hat{\boldsymbol{\beta}} = (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{Y}$
- E) aucune des réponses proposées

152. Dans le modèle

$$\mathbb{E}[Y \mid X_1, X_2] = \beta_0 + \beta_1 X_1 + \beta_2 X_2,$$

le coefficient β_1 s'interprète comme :

- A) l'effet d'une hausse d'une unité de X_1 , sans tenir compte de X_2
- B) l'effet d'une hausse d'une unité de X_1 , à X_2 fixé
- C) la corrélation entre X_1 et Y
- D) la variance expliquée par X_1
- E) aucune des réponses proposées

153. On estime

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i.$$

Si $\hat{\beta}_1 = 2$, $\hat{\beta}_2 = -1$ et $\hat{\beta}_0 = 5$, la valeur prédite pour $X_1 = 3$ et $X_2 = 4$ est :

- A) 3
- B) 5
- C) 7
- D) 15
- E) aucune des réponses proposées

154. Dans une régression multiple avec constante, si l'on ajoute une variable explicative supplémentaire, alors :

- A) le R^2 ne peut pas diminuer
- B) le R^2 ajusté ne peut pas diminuer
- C) tous les coefficients déjà présents restent inchangés
- D) la somme des résidus n'est plus nécessairement nulle
- E) aucune des réponses proposées

155. Le modèle

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i$$

est estimé avec $n = 80$ observations. Il contient une constante et deux variables explicatives. Le nombre de degrés de liberté résiduels est :

- A) 80
- B) 79
- C) 78
- D) 77
- E) aucune des réponses proposées

156. Dans le modèle

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

la matrice de projection sur l'espace engendré par les colonnes de $\mathbf{X}$ est :

- A) $\mathbf{H} = \mathbf{X}^\top \mathbf{X}$
- B) $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$
- C) $\mathbf{H} = (\mathbf{X} \mathbf{X}^\top)^{-1}$
- D) $\mathbf{H} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$
- E) aucune des réponses proposées

157. Le vecteur des valeurs ajustées dans une régression multiple s'écrit :

- A) $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$
- B) $\hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$
- C) $\hat{\mathbf{Y}} = \mathbf{X}^\top \mathbf{Y}$
- D) $\hat{\mathbf{Y}} = \hat{\boldsymbol{\beta}} - \mathbf{Y}$
- E) aucune des réponses proposées

158. Le vecteur des résidus dans une régression multiple est :

- A) $\hat{\boldsymbol{\varepsilon}} = \mathbf{X}\hat{\boldsymbol{\beta}}$
- B) $\hat{\boldsymbol{\varepsilon}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$
- C) $\hat{\boldsymbol{\varepsilon}} = \mathbf{X}^\top \mathbf{Y}$
- D) $\hat{\boldsymbol{\varepsilon}} = \mathbf{Y} + \mathbf{X}\hat{\boldsymbol{\beta}}$
- E) aucune des réponses proposées

159. Dans une régression multiple avec constante, les équations normales impliquent notamment :

- A) $\mathbf{X}^\top \hat{\boldsymbol{\varepsilon}} = \mathbf{0}$
- B) $\mathbf{X}\hat{\boldsymbol{\varepsilon}} = \mathbf{0}$
- C) $\hat{\boldsymbol{\varepsilon}} = \mathbf{0}$
- D) $\mathbf{Y}^\top \hat{\boldsymbol{\varepsilon}} = 1$
- E) aucune des réponses proposées

160. Dans le modèle

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i,$$

si X_2 est omise, l'estimateur de β_1 est en général biaisé lorsque :

- A) $\beta_2 = 0$
- B) X_1 et X_2 sont non corrélées
- C) X_2 influence Y et est corrélée avec X_1

- D) X_2 est qualitative
- E) aucune des réponses proposées

161. Si deux colonnes de $\mathbf{X}$ sont exactement identiques, alors :

- A) $\mathbf{X}^\top \mathbf{X}$ est inversible
- B) les coefficients sont identifiables de manière unique
- C) il y a colinéarité parfaite
- D) le R^2 vaut nécessairement zéro
- E) aucune des réponses proposées

162. Une forte multicollinéarité entre deux variables explicatives a souvent pour conséquence :

- A) des coefficients estimés avec de grands écarts-types
- B) des résidus tous nuls
- C) un R^2 nécessairement négatif
- D) une impossibilité d'inclure une constante
- E) aucune des réponses proposées

163. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \varepsilon_i,$$

où $D_i = 1$ pour le groupe B et $D_i = 0$ pour le groupe A. À X fixé, l'écart moyen entre le groupe B et le groupe A est :

- A) β_0
- B) β_1
- C) β_2
- D) $\beta_1 + \beta_2$
- E) aucune des réponses proposées

164. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i + \varepsilon_i.$$

La pente en X pour le groupe $D = 0$ est :

- A) β_1
- B) β_2
- C) β_3
- D) $\beta_1 + \beta_3$
- E) aucune des réponses proposées

165. Dans le même modèle,

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i + \varepsilon_i,$$

la pente en X pour le groupe $D = 1$ est :

- A) β_1
- B) β_2
- C) β_3
- D) $\beta_1 + \beta_3$
- E) aucune des réponses proposées

166. Dans le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i + \varepsilon_i,$$

l'écart moyen entre $D = 1$ et $D = 0$, pour une valeur donnée $X = x$, est :

- A) β_2
- B) β_3
- C) $\beta_2 + \beta_3 x$
- D) $\beta_1 + \beta_2 + \beta_3$
- E) aucune des réponses proposées

167. On estime un modèle avec une variable qualitative **region** ayant quatre modalités, et une constante. Combien de variables indicatrices faut-il inclure pour éviter la colinéarité parfaite ?

- A) 1
- B) 2
- C) 3
- D) 4
- E) aucune des réponses proposées

168. Dans une régression multiple, le test global de Fisher teste généralement :

- A) si tous les coefficients, constante incluse, sont égaux à zéro
- B) si tous les coefficients des variables explicatives sont égaux à zéro
- C) si les résidus suivent exactement une loi normale
- D) si les variables explicatives sont indépendantes
- E) aucune des réponses proposées

169. On estime un modèle avec $n = 50$ observations et $p = 5$ paramètres, constante incluse. La somme des carrés résiduels vaut $SCR = 90$. L'estimateur usuel de σ^2 est :

- A) $90/50$
- B) $90/49$
- C) $90/45$
- D) $90/5$
- E) aucune des réponses proposées

170. Dans un modèle linéaire multiple, l'écart-type associé à $\hat{\beta}_j$ sert notamment à :

- A) calculer une statistique de test pour $H_0 : \beta_j = 0$
- B) calculer le nombre exact de variables explicatives
- C) imposer que le coefficient soit positif
- D) garantir que le R^2 augmente
- E) aucune des réponses proposées

171. Deux modèles linéaires emboîtés ont des sommes des carrés résiduels $SCR_0 = 120$ et $SCR_1 = 100$, où le modèle complet ajoute 2 paramètres. Le modèle complet a 40 degrés de liberté résiduels. La statistique de Fisher de comparaison vaut :

$$F = \frac{(SCR_0 - SCR_1)/2}{SCR_1/40}.$$

- A) 2
- B) 4
- C) 8
- D) 10
- E) aucune des réponses proposées

172. Dans une régression multiple, une observation peut avoir un fort levier lorsque :

- A) sa valeur de Y est proche de la moyenne
- B) ses valeurs des variables explicatives sont atypiques relativement aux autres observations
- C) son résidu est nécessairement nul
- D) elle appartient toujours au groupe de référence
- E) aucune des réponses proposées

173. La distance de Cook vise principalement à repérer :

- A) les variables explicatives inutiles
- B) les observations dont la suppression peut modifier fortement l'ajustement
- C) les modèles sans constante
- D) les variables parfaitement normales
- E) aucune des réponses proposées

174. On estime

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i.$$

Si l'on centre X_1 et X_2 , sans modifier Y , alors :

- A) les coefficients de pente changent nécessairement
- B) les coefficients de pente restent inchangés, mais la constante peut changer
- C) le R^2 devient nécessairement nul
- D) les résidus changent nécessairement
- E) aucune des réponses proposées

175. Dans une régression multiple, le coefficient de détermination ajusté pénalise :

- A) le nombre de variables explicatives incluses dans le modèle
- B) uniquement la constante
- C) uniquement les observations extrêmes
- D) uniquement les variables qualitatives
- E) aucune des réponses proposées

176. On considère le modèle

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

où $\mathbf{X}$ est une matrice $n \times p$ et $\boldsymbol{\beta}$ un vecteur $p \times 1$. Alors $\mathbf{X}\boldsymbol{\beta}$ est :

- A) un scalaire
- B) un vecteur $p \times 1$
- C) un vecteur $n \times 1$
- D) une matrice $n \times p$
- E) aucune des réponses proposées

177. Si $\mathbf{X}$ est une matrice $n \times p$, alors $\mathbf{X}^\top \mathbf{X}$ est :

- A) une matrice $n \times n$
- B) une matrice $p \times p$
- C) une matrice $n \times p$
- D) une matrice $p \times n$
- E) aucune des réponses proposées

178. Dans le modèle linéaire multiple, les équations normales peuvent s'écrire :

- A) $\mathbf{X}^\top(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}$
- B) $\mathbf{X}(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}$
- C) $\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{0}$
- D) $\mathbf{X}^\top \mathbf{X} = \mathbf{0}$
- E) aucune des réponses proposées

179. Si

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top,$$

alors le vecteur des valeurs ajustées est :

- A) $\mathbf{Y} - \mathbf{H}\mathbf{Y}$
- B) $\mathbf{H}\mathbf{Y}$
- C) $\mathbf{X}^\top \mathbf{Y}$
- D) $\mathbf{H}\hat{\boldsymbol{\beta}}$
- E) aucune des réponses proposées

180. Avec la même matrice $\mathbf{H}$, le vecteur des résidus peut s'écrire :

- A) $\mathbf{H}\mathbf{Y}$
- B) $\mathbf{X}\mathbf{Y}$
- C) $(\mathbf{I}_n - \mathbf{H})\mathbf{Y}$
- D) $\mathbf{H}\hat{\boldsymbol{\beta}}$
- E) aucune des réponses proposées

181. Si $\mathbf{X}^\top \mathbf{X}$ est inversible, la matrice

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$$

vérifie :

- A) $\mathbf{H}^\top = -\mathbf{H}$ et $\mathbf{H}^2 = \mathbf{0}$
- B) $\mathbf{H}^\top = \mathbf{H}$ et $\mathbf{H}^2 = \mathbf{H}$
- C) $\mathbf{H}$ est toujours diagonale
- D) $\mathbf{H}$ est toujours inversible
- E) aucune des réponses proposées

182. Sous l'hypothèse $\text{Var}(\boldsymbol{\varepsilon} | \mathbf{X}) = \sigma^2 \mathbf{I}_n$, la matrice de variance-covariance de $\hat{\boldsymbol{\beta}}$ est :

- A) $\sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$
- B) $\sigma^2 \mathbf{X}^\top \mathbf{X}$
- C) $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{Y}$
- D) $\sigma^2 \mathbf{X}$
- E) aucune des réponses proposées

183. Dans un modèle linéaire multiple avec p paramètres, l'estimateur usuel de σ^2 est :

- A) $\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}/n$
- B) $\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}/(n-1)$
- C) $\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}/(n-p)$
- D) $\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}/p$
- E) aucune des réponses proposées

184. Pour une nouvelle observation décrite par un vecteur $\mathbf{x}_0$ de dimension $p \times 1$, la valeur prédite de l'espérance conditionnelle est :

- A) $\hat{\beta}^\top Y$
- B) $x_0^\top \hat{\beta}$
- C) $X^\top x_0$
- D) $x_0^\top Y$

E) aucune des réponses proposées

185. On estime un modèle avec $n = 60$ observations, une constante et deux variables explicatives. Le nombre de degrés de liberté résiduels est :

- A) 60
- B) 59
- C) 58
- D) 57

E) aucune des réponses proposées

186. Dans un modèle linéaire multiple, tester simultanément

$$H_0 : \beta_2 = \beta_3 = 0$$

revient à tester :

- A) une seule restriction
- B) trois restrictions
- C) deux restrictions
- D) aucune restriction

E) aucune des réponses proposées

187. Deux modèles emboîtés ont des sommes des carrés résiduels $SCR_0 = 200$ et $SCR_1 = 160$, où le modèle complet ajoute 2 paramètres. Le modèle complet a 40 degrés de liberté résiduels. La statistique de Fisher

$$F = \frac{(SCR_0 - SCR_1)/2}{SCR_1/40}$$

vaut :

- A) 2
- B) 5
- C) 10
- D) 20

E) aucune des réponses proposées

188. Le vrai modèle est

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i,$$

avec $\beta_2 > 0$ et $\text{Cov}(X_1, X_2) < 0$. Si l'on omet X_2 , le biais sur le coefficient de X_1 est plutôt :

- A) positif
- B) négatif
- C) nécessairement nul
- D) impossible à discuter

E) aucune des réponses proposées

189. Le théorème de Frisch-Waugh-Lovell permet d'interpréter le coefficient de X_1 dans une régression multiple comme :

- A) le coefficient de la régression de Y sur X_1 seulement
- B) le coefficient de la régression de X_1 sur les autres variables explicatives
- C) le coefficient de la régression des résidus de Y sur les autres variables contre les résidus de X_1 sur les autres variables
- D) le coefficient de corrélation entre Y et X_1
- E) aucune des réponses proposées

190. Dans un modèle linéaire multiple, si l'on remplace X_1 par $X_1 - \bar{X}_1$, sans modifier les autres variables explicatives ni Y , alors :

- A) tous les coefficients de pente changent nécessairement
- B) le coefficient de X_1 reste inchangé, mais la constante peut changer
- C) le R^2 devient nécessairement nul
- D) les valeurs ajustées changent nécessairement
- E) aucune des réponses proposées

191. On estime un modèle avec une variable X_1 , puis on remplace X_1 par $Z_1 = X_1/100$. Si le coefficient de X_1 était $\hat{\beta}_1$, le coefficient de Z_1 vaut :

- A) $100\hat{\beta}_1$
- B) $\hat{\beta}_1/100$
- C) $\hat{\beta}_1$
- D) $\hat{\beta}_1^2$
- E) aucune des réponses proposées

192. Une variable qualitative possède 5 modalités. Dans une régression avec constante, combien de variables indicatrices doit-on inclure ?

- A) 1
- B) 3
- C) 5
- D) 4
- E) aucune des réponses proposées

193. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \varepsilon_i,$$

où $D_i = 1$ pour le groupe B et $D_i = 0$ pour le groupe A. Pour le groupe B, la valeur prédite lorsque $X = x$ est :

- A) $\beta_0 + \beta_1 x$
- B) $\beta_0 + \beta_2$
- C) $\beta_0 + \beta_1 x + \beta_2$
- D) $\beta_1 + \beta_2 x$
- E) aucune des réponses proposées

194. On estime

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i + \varepsilon_i.$$

La pente en X dans le groupe $D = 1$ est :

- A) β_1
- B) β_2
- C) β_3

- D) $\beta_1 + \beta_3$
- E) aucune des réponses proposées

195. Dans le même modèle,

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i + \varepsilon_i,$$

l'écart moyen entre le groupe $D = 1$ et le groupe $D = 0$, pour $X = x$, est :

- A) β_2
- B) β_3
- C) $\beta_2 + \beta_3 x$
- D) $\beta_1 + \beta_2 + \beta_3$
- E) aucune des réponses proposées

196. Dans un modèle

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \varepsilon_i,$$

sans interaction entre X_i et D_i , les deux groupes $D = 0$ et $D = 1$ ont :

- A) des droites parallèles
- B) des pentes nécessairement opposées
- C) la même constante
- D) des résidus nécessairement nuls
- E) aucune des réponses proposées

197. Dans le modèle

$$\log(Y_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i,$$

si $\hat{\beta}_1 = 0.05$, alors une hausse d'une unité de X_1 , à X_2 fixé, est associée approximativement à :

- A) une hausse de Y de 0.05 unité
- B) une hausse de Y de 5%
- C) une baisse de Y de 5%
- D) une hausse de $\log(Y)$ de 5 unités
- E) aucune des réponses proposées

198. Dans le modèle

$$Y_i = \beta_0 + \beta_1 \log(X_i) + \beta_2 Z_i + \varepsilon_i,$$

si $\hat{\beta}_1 = 4$, alors une hausse approximative de 1% de X , à Z fixé, est associée à :

- A) une hausse de Y d'environ 0.04
- B) une hausse de Y d'environ 4
- C) une hausse de Y d'environ 400
- D) une multiplication de Y par 4
- E) aucune des réponses proposées

199. Dans une régression multiple, le R^2 ajusté peut diminuer lorsqu'on ajoute une variable explicative parce que :

- A) le R^2 diminue toujours lorsqu'on ajoute une variable
- B) le gain d'ajustement peut être trop faible relativement à la perte de degré de liberté
- C) la constante disparaît automatiquement
- D) les résidus deviennent tous positifs
- E) aucune des réponses proposées

200. Dans un modèle avec $n = 100$ observations et $p = 5$ paramètres, constante incluse, la moyenne des leviers h_{ii} est :

- A) 5
- B) 0.05
- C) 0.95
- D) 100
- E) aucune des réponses proposées

201. On utilise la base `mtcars`, disponible dans R. On estime le modèle suivant :

```
reg <- lm(mpg ~ wt + hp + am, data = mtcars)
summary(reg)
```

La sortie obtenue est partiellement donnée ci-dessous :

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  34.0029      2.6427   12.87  2.8e-13 ***
wt           -2.8786      0.9050   -3.18  0.0036 **
hp           -0.0375      0.0096   -3.90  0.0005 ***
am            2.0837      1.3764    1.51  0.1413

Residual standard error: 2.538 on 28 degrees of freedom
Multiple R-squared:  0.8399, Adjusted R-squared:  0.8227
F-statistic: 48.96 on 3 and 28 DF, p-value: 2.9e-11
```

Combien d'observations ont été utilisées pour estimer ce modèle ?

- A) 28
- B) 29
- C) 31
- D) 32
- E) aucune des réponses proposées

202. Dans la sortie précédente, la statistique de test associée au coefficient de `wt` vaut environ :

- A) -0.31
- B) -3.18
- C) 3.18
- D) -31.8
- E) aucune des réponses proposées

203. Au seuil de 5%, quelle variable n'est pas significative dans ce modèle ?

- A) `wt`
- B) `hp`
- C) `am`
- D) toutes les variables sont significatives
- E) aucune des réponses proposées

204. Comment interpréter le coefficient associé à `hp` ?

- A) Une hausse d'une unité de `hp` augmente `mpg` de 0.0375, toutes choses égales par ailleurs.
- B) Une hausse d'une unité de `hp` diminue `mpg` d'environ 0.0375, toutes choses égales par ailleurs.

- C) Une hausse d'une unité de **hp** multiplie **mpg** par $\exp(-0.0375)$.
- D) Le coefficient n'est pas interprétable car il est négatif.
- E) aucune des réponses proposées

205. Pour une voiture telle que

$$\text{wt} = 3, \quad \text{hp} = 120, \quad \text{am} = 1,$$

la valeur prédite de **mpg** est environ :

- A) 12.4
- B) 18.7
- C) 23.0
- D) 34.0
- E) aucune des réponses proposées

206. Le R^2 ajusté vaut 0.8227. Par rapport au R^2 usuel, il :

- A) pénalise le nombre de variables explicatives incluses dans le modèle
- B) est toujours supérieur au R^2
- C) ne dépend pas du nombre d'observations
- D) est égal à la somme des résidus
- E) aucune des réponses proposées

207. L'écart-type résiduel vaut 2.538. Cela signifie que :

- A) tous les résidus valent exactement 2.538
- B) le R^2 vaut 2.538
- C) la moyenne des résidus vaut 2.538
- D) les erreurs de prédiction ont une dispersion typique d'environ 2.538 unités de **mpg**
- E) aucune des réponses proposées

208. On compare le modèle précédent avec le modèle réduit

```
reg0 <- lm(mpg ~ wt + hp, data = mtcars)
```

Le test de comparaison entre **reg0** et **reg** revient à tester :

- A) si **am** apporte une information supplémentaire une fois **wt** et **hp** inclus
- B) si **wt** est utile
- C) si **hp** est utile
- D) si la constante est nulle
- E) aucune des réponses proposées

209. Si **am** est une variable indicatrice valant 1 pour les voitures manuelles et 0 pour les voitures automatiques, alors le coefficient 2.0837 signifie que :

- A) les voitures manuelles consomment toujours exactement 2.0837 unités de plus
- B) à **wt** et **hp** fixés, les voitures manuelles ont une valeur prédite de **mpg** supérieure d'environ 2.08
- C) la probabilité qu'une voiture soit manuelle vaut 2.0837
- D) le modèle est nécessairement mal spécifié
- E) aucune des réponses proposées

210. On remplace `hp` par

$$hp10 = hp/10.$$

Quel serait le coefficient associé à `hp10`, approximativement ?

- A) -0.00375
- B) -0.0375
- C) -0.075
- D) -0.375
- E) aucune des réponses proposées

211. Un intervalle de confiance approximatif à 95% pour le coefficient de `wt` est :

- A) $[-3.78; -1.97]$
- B) $[-2.88; 0.91]$
- C) $[-4.65; -1.11]$
- D) $[1.11; 4.65]$
- E) aucune des réponses proposées

212. La p-value du test global de Fisher est très petite. Cela signifie que :

- A) au moins une des variables explicatives est utile pour expliquer `mpg`
- B) toutes les variables ont exactement le même coefficient
- C) les résidus sont nécessairement normaux
- D) le modèle explique 100% de la variabilité
- E) aucune des réponses proposées

213. On utilise maintenant la base `airquality`. On estime le modèle suivant :

```
reg_air <- lm(Ozone ~ Solar.R + Wind + Temp, data = airquality)
summary(reg_air)
```

La sortie obtenue est :

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -64.3421    23.0547  -2.79  0.0062 **
Solar.R        0.0598     0.0232   2.58  0.0112 *
Wind         -3.3336     0.6544  -5.09  1.5e-06 ***
Temp          1.6521     0.2535   6.52  2.4e-09 ***

Residual standard error: 21.18 on 107 degrees of freedom
Multiple R-squared:  0.6059, Adjusted R-squared:  0.5948
F-statistic: 54.83 on 3 and 107 DF, p-value: < 2.2e-16
```

Combien d'observations complètes ont été utilisées ?

- A) 107
- B) 111
- C) 153
- D) 110
- E) aucune des réponses proposées

214. Dans ce modèle, le coefficient associé à `Wind` signifie que :

- A) à `Solar.R` et `Temp` fixés, une hausse d'une unité de `Wind` est associée à une baisse moyenne d'environ 3.33 de `Ozone`

- B) une hausse d'une unité de `Wind` multiplie `Ozone` par $\exp(-3.3336)$
- C) `Wind` explique exactement 3.33% de la variance
- D) la variable `Wind` n'est pas significative
- E) aucune des réponses proposées

215. Quelle variable présente la statistique de test la plus grande en valeur absolue ?

- A) `Solar.R`
- B) `Wind`
- C) `Intercept`
- D) `Temp`
- E) aucune des réponses proposées

216. Un intervalle de confiance approximatif à 95% pour le coefficient de `Solar.R` est :

- A) $[-0.046; 0.046]$
- B) $[0.014; 0.105]$
- C) $[0.060; 0.253]$
- D) $[0.106; 0.152]$
- E) aucune des réponses proposées

217. Pour une journée telle que

$$\text{Solar.R} = 200, \quad \text{Wind} = 10, \quad \text{Temp} = 80,$$

la valeur prédite de `Ozone` est environ :

- A) 12.1
- B) 28.4
- C) 46.5
- D) 80.0
- E) aucune des réponses proposées

218. Au seuil de 5%, que peut-on dire des trois variables explicatives du modèle `airquality` ?

- A) elles sont toutes significatives
- B) aucune n'est significative
- C) seule `Solar.R` est significative
- D) seule `Wind` est significative
- E) aucune des réponses proposées

219. D'après le coefficient de `Temp`, une hausse de 10 unités de `Temp`, toutes choses égales par ailleurs, est associée à :

- A) une baisse d'environ 1.65 de `Ozone`
- B) une hausse d'environ 1.65 de `Ozone`
- C) une baisse d'environ 16.5 de `Ozone`
- D) une hausse d'environ 16.5 de `Ozone`
- E) aucune des réponses proposées

220. Dans ce modèle, combien de paramètres sont estimés, constante incluse ?

- A) 2
- B) 3

- C) 4
- D) 107
- E) aucune des réponses proposées

221. Le $R^2 = 0.6059$ signifie approximativement que :

- A) 60.59% des résidus sont nuls
- B) le modèle explique environ 60.59% de la variabilité observée de `Ozone`
- C) chaque variable est significative à 60.59%
- D) l'écart-type résiduel vaut 0.6059
- E) aucune des réponses proposées

222. L'interprétation de la constante -64.3421 est délicate parce que :

- A) elle est toujours égale à zéro dans un modèle linéaire
- B) elle mesure directement le R^2
- C) elle correspond à une probabilité négative
- D) elle correspond à la prédiction lorsque `Solar.R`, `Wind` et `Temp` valent zéro, ce qui peut être hors du domaine pertinent
- E) aucune des réponses proposées

223. On considère enfin la sortie R suivante, comparant deux modèles emboîtés :

```
Analysis of Variance Table

Model 1: y ~ x1 + x2
Model 2: y ~ x1 + x2 + x3 + x4
  Res.Df  RSS Df Sum of Sq    F Pr(>F)
1      56 420
2      54 360  2        60  4.5  0.015
```

Le test compare ici :

- A) seulement la constante
- B) seulement x_1
- C) l'ajout conjoint de x_3 et x_4 , une fois x_1 et x_2 inclus
- D) la normalité des résidus
- E) aucune des réponses proposées

224. La statistique de Fisher affichée dans la sortie précédente vaut :

- A) 2.0
- B) 4.5
- C) 15.0
- D) 60.0
- E) aucune des réponses proposées

225. D'après la p-value 0.015, au seuil de 5%, on conclut que :

- A) on ne rejette pas le modèle réduit
- B) le test est impossible à interpréter
- C) on rejette le modèle complet
- D) l'ajout conjoint de x_3 et x_4 améliore significativement le modèle
- E) aucune des réponses proposées

226. On utilise la base `iris`, disponible dans R. On estime le modèle suivant :

```
reg_iris <- lm(Sepal.Length ~ Sepal.Width + Petal.Length + Species,
               data = iris)
summary(reg_iris)
```

La sortie obtenue est partiellement donnée ci-dessous :

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    2.2514     0.3698    6.09 1.2e-08 ***
Sepal.Width     0.5955     0.0693    8.59 < 2e-16 ***
Petal.Length    0.4719     0.0171   27.57 < 2e-16 ***
Speciesversicolor -0.3438     0.0930   -3.70 0.00031 ***
Speciesvirginica -0.7419     0.1022   -7.26 2.0e-11 ***

Residual standard error: 0.3145 on 145 degrees of freedom
Multiple R-squared: 0.8586, Adjusted R-squared: 0.8547
F-statistic: 220.1 on 4 and 145 DF, p-value: < 2.2e-16
```

Combien d'observations ont été utilisées pour estimer ce modèle ?

- A) 145
 - B) 146
 - C) 149
 - D) 150
 - E) aucune des réponses proposées
227. Dans la sortie précédente, quelle est la modalité de référence pour la variable `Species` ?
- A) `setosa`
 - B) `versicolor`
 - C) `virginica`
 - D) aucune modalité de référence n'est utilisée
 - E) aucune des réponses proposées
228. Le coefficient associé à `Sepal.Width` vaut 0.5955. Il signifie que :
- A) une hausse d'une unité de `Sepal.Width` multiplie `Sepal.Length` par 0.5955
 - B) à `Petal.Length` et `Species` fixés, une hausse d'une unité de `Sepal.Width` est associée à une hausse moyenne d'environ 0.596 de `Sepal.Length`
 - C) `Sepal.Width` explique 59.55% de la variance
 - D) le coefficient n'est pas interprétable car il est positif
 - E) aucune des réponses proposées
229. Le coefficient associé à `Speciesversicolor` vaut -0.3438. Cela signifie que :
- A) les fleurs `versicolor` ont toujours une longueur de sépale négative
 - B) les fleurs `versicolor` sont la modalité de référence
 - C) à `Sepal.Width` et `Petal.Length` fixés, les fleurs `versicolor` ont une valeur prédite de `Sepal.Length` inférieure d'environ 0.344 à celle des fleurs `setosa`
 - D) `Speciesversicolor` n'est pas significative
 - E) aucune des réponses proposées
230. Pour une fleur `versicolor` telle que

$$\text{Sepal.Width} = 3, \quad \text{Petal.Length} = 4,$$

la valeur prédite de `Sepal.Length` est environ :

- A) 4.21
- B) 5.58
- C) 6.32
- D) 7.45
- E) aucune des réponses proposées

231. Quelle variable présente la statistique de test la plus grande en valeur absolue ?

- A) `Sepal.Width`
- B) `Speciesversicolor`
- C) `Petal.Length`
- D) `Speciesvirginica`
- E) aucune des réponses proposées

232. Un intervalle de confiance approximatif à 95% pour le coefficient de `Petal.Length` est :

- A) [0.455; 0.489]
- B) [0.405; 0.539]
- C) [0.438; 0.505]
- D) [0.472; 0.596]
- E) aucune des réponses proposées

233. Le $R^2 = 0.8586$ signifie approximativement que :

- A) 85.86% des coefficients sont significatifs
- B) le modèle explique environ 85.86% de la variabilité observée de `Sepal.Length`
- C) la moyenne des résidus vaut 0.8586
- D) l'écart-type résiduel vaut 0.8586
- E) aucune des réponses proposées

234. On compare maintenant deux modèles emboîtés :

```
reg0 <- lm(Sepal.Length ~ Sepal.Width + Petal.Length, data = iris)
reg1 <- lm(Sepal.Length ~ Sepal.Width + Petal.Length + Species, data = iris)
anova(reg0, reg1)
```

La sortie est :

```
Analysis of Variance Table

Model 1: Sepal.Length ~ Sepal.Width + Petal.Length
Model 2: Sepal.Length ~ Sepal.Width + Petal.Length + Species
  Res.Df  RSS Df Sum of Sq    F    Pr(>F)
1     147 17.94
2     145 14.35  2      3.59 18.14 8.1e-08
```

Ce test compare :

- A) seulement la constante
- B) seulement `Sepal.Width`
- C) l'ajout conjoint des indicatrices associées à `Species`, une fois `Sepal.Width` et `Petal.Length` inclus
- D) la normalité des résidus
- E) aucune des réponses proposées

235. Dans la sortie précédente, le nombre de restrictions testées est :

- A) 1
- B) 2
- C) 3
- D) 145
- E) aucune des réponses proposées

236. D'après la p-value 8.1×10^{-8} , au seuil de 5%, on conclut que :

- A) on ne rejette pas le modèle réduit
- B) les deux modèles sont exactement équivalents
- C) le modèle complet doit être rejeté
- D) l'ajout de **Species** améliore significativement le modèle
- E) aucune des réponses proposées

237. On estime maintenant le modèle suivant sur la base **mtcars** :

```
reg_int <- lm(mpg ~ wt * am + hp, data = mtcars)
summary(reg_int)
```

La sortie partielle est :

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  31.4161     3.0201   10.40  1.1e-10 ***
wt           -3.7859     0.7856   -4.82  5.0e-05 ***
am            9.0843     4.2555    2.13  0.0419 *
hp           -0.0267     0.0090   -2.97  0.0062 **
wt:am        -2.4759     1.4246   -1.74  0.0934 .

Residual standard error: 2.32 on 27 degrees of freedom
Multiple R-squared:  0.8720, Adjusted R-squared:  0.8530
```

Dans ce modèle, la pente associée à **wt** pour les voitures automatiques, c'est-à-dire lorsque **am** = 0, est :

- A) -3.7859
- B) 9.0843
- C) -2.4759
- D) -3.7859 - 2.4759
- E) aucune des réponses proposées

238. Dans le même modèle, la pente associée à **wt** pour les voitures manuelles, c'est-à-dire lorsque **am** = 1, est environ :

- A) -3.7859
- B) -2.4759
- C) -6.2618
- D) 9.0843
- E) aucune des réponses proposées

239. Au seuil de 5%, que peut-on dire du terme d'interaction **wt:am** ?

- A) il est significatif car son estimateur est négatif
- B) il n'est pas significatif au seuil de 5%

- C) il est forcément nul car il s'agit d'une interaction
- D) il rend le modèle impossible à interpréter
- E) aucune des réponses proposées

240. Pour une voiture manuelle telle que

$$\text{wt} = 3, \quad \text{hp} = 120, \quad \text{am} = 1,$$

la valeur prédite de `mpg` est environ :

- A) 12.3
- B) 15.1
- C) 18.5
- D) 25.4
- E) aucune des réponses proposées

Partie 3 — Modèles linéaires généralisés : logistique et Poisson

241. Dans une régression logistique, on a

$$\log\left(\frac{p}{1-p}\right) = -1 + 0.5x.$$

Pour $x = 2$, la probabilité prédite p vaut :

- A) 0
- B) 0.5
- C) 0.73
- D) 1
- E) aucune des réponses proposées

242. Dans une régression logistique, un coefficient $\hat{\beta} = 0.8$ associé à une variable X signifie que, lorsque X augmente d'une unité, toutes choses égales par ailleurs :

- A) la probabilité est multipliée par 0.8
- B) la probabilité augmente de 80%
- C) les odds sont multipliées par $\exp(0.8)$
- D) les odds diminuent de $\exp(0.8)$
- E) aucune des réponses proposées

243. On estime une régression logistique avec une variable qualitative `sexe`, où `Homme` est la référence. Le coefficient associé à `sexeFemme` vaut -0.4 . On peut dire que :

- A) les femmes ont une probabilité négative
- B) les femmes ont des odds multipliées par $\exp(-0.4)$ par rapport aux hommes, toutes choses égales par ailleurs
- C) les femmes ont une probabilité inférieure de 40 points de pourcentage
- D) le modèle est impossible à interpréter
- E) aucune des réponses proposées

244. On estime

$$\log\left(\frac{p}{1-p}\right) = -2 + 1.5x.$$

Pour $x = 1$, la probabilité prédite est approximativement :

- A) 0.12
- B) 0.27
- C) 0.38
- D) 0.82
- E) aucune des réponses proposées

245. Dans un modèle logistique, la règle de classification $\hat{p} > 0.5$ est équivalente à :

- A) $\hat{\eta} < 0$, où $\hat{\eta}$ est le prédicteur linéaire
- B) $\hat{\eta} = 0$
- C) $\hat{\eta} < 1$
- D) $\hat{\eta} > 0$
- E) aucune des réponses proposées

246. Dans une régression de Poisson avec lien logarithmique,

$$\log(\mathbb{E}[Y|X]) = \beta_0 + \beta_1 X.$$

Si $\hat{\beta}_1 = 0.2$, alors une hausse d'une unité de X multiplie l'espérance conditionnelle par environ :

- A) 0.2
- B) 1.02
- C) 1.22
- D) 2
- E) aucune des réponses proposées

247. Dans un modèle de Poisson avec offset,

$$\log(\mathbb{E}[N|X, E]) = \log(E) + \beta_0 + \beta_1 X.$$

À X fixé, si l'exposition E double, alors l'espérance de N :

- A) reste inchangée
- B) double
- C) est divisée par deux
- D) augmente de β_1
- E) aucune des réponses proposées

248. Dans un modèle de Poisson standard, on suppose que :

- A) $\text{Var}(Y|X) = 1$
- B) $\text{Var}(Y|X) = \mathbb{E}[Y|X]$
- C) $\text{Var}(Y|X) = 0$
- D) $\text{Var}(Y|X)$ est toujours supérieure au carré de l'espérance
- E) aucune des réponses proposées

249. Dans un GLM de Poisson, on observe une déviance résiduelle de 95 pour 30 degrés de liberté. Cela suggère plutôt :

- A) une sous-dispersion très forte
- B) une absence totale de relation entre X et Y
- C) une possible surdispersion
- D) une séparation parfaite
- E) aucune des réponses proposées

250. En présence de surdispersion dans un modèle de Poisson, une approche possible est :

- A) d'utiliser une régression linéaire sans constante
- B) d'utiliser un modèle quasi-Poisson ou binomial négatif
- C) de supprimer toutes les observations avec $Y = 0$
- D) de remplacer le lien logarithmique par une fonction constante
- E) aucune des réponses proposées

251. On compare deux GLM emboîtés. Le modèle réduit a une déviance résiduelle de 120.5, le modèle complet une déviance résiduelle de 108.1. Le modèle complet ajoute 2 paramètres. La statistique du test du rapport de vraisemblance vaut :

- A) 2
- B) 12.4
- C) 108.1/120.5
- D) 120.5 + 108.1
- E) aucune des réponses proposées

252. Pour comparer deux modèles estimés par maximum de vraisemblance sur les mêmes données, l'AIC :

- A) doit toujours être le plus grand possible
- B) est égal au R^2
- C) pénalise la complexité du modèle
- D) ne dépend pas de la vraisemblance
- E) aucune des réponses proposées

253. On estime le modèle logistique

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i,$$

où $D_i = 1$ pour le groupe B et 0 pour le groupe A. L'effet de X sur le log-odds dans le groupe B est :

- A) β_1
- B) β_2
- C) β_3
- D) $\beta_1 + \beta_3$
- E) aucune des réponses proposées

254. Dans le même modèle,

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i,$$

l'écart de log-odds entre le groupe B et le groupe A, pour une valeur $X = x$, est :

- A) β_2
- B) β_3
- C) $\beta_2 + \beta_3 x$
- D) $\beta_1 + \beta_2 + \beta_3$
- E) aucune des réponses proposées

255. Si l'on transforme une variable binaire Y en $1 - Y$ et que l'on réestime une régression logistique avec les mêmes variables explicatives, alors :

- A) les coefficients changent de signe
- B) les coefficients sont inchangés
- C) les probabilités prédites sont inchangées
- D) le modèle devient un modèle de Poisson
- E) aucune des réponses proposées

256. Dans un GLM, la fonction de lien g relie :

- A) les résidus aux variables explicatives
- B) la variance à la déviance
- C) l'espérance conditionnelle au prédicteur linéaire
- D) l'AIC au BIC
- E) aucune des réponses proposées

257. Le modèle linéaire classique avec erreurs normales peut être vu comme un GLM avec :

- A) loi de Poisson et lien logarithmique
- B) loi binomiale et lien logit
- C) loi normale et lien identité
- D) loi exponentielle et lien logit
- E) aucune des réponses proposées

258. On estime un modèle de Poisson avec offset :

$$\log(\mu_i) = \log(E_i) - 4 + 0.5X_i.$$

Pour $E_i = 100$ et $X_i = 1$, la moyenne prédite μ_i vaut approximativement :

- A) 0.03
- B) 0.30
- C) 3.02
- D) 30.2
- E) aucune des réponses proposées

259. Dans une régression logistique, une séparation parfaite des données peut conduire à :

- A) des coefficients estimés très grands en valeur absolue ou non finis
- B) un R^2 exactement égal à 1 au sens des moindres carrés
- C) une variance résiduelle négative
- D) une loi de Poisson
- E) aucune des réponses proposées

260. Dans un modèle logistique, les effets marginaux sur la probabilité :

- A) sont toujours égaux aux coefficients du modèle
- B) sont constants pour toutes les valeurs de X
- C) dépendent généralement de la valeur des variables explicatives
- D) sont toujours nuls lorsque le coefficient est positif
- E) aucune des réponses proposées

261. Dans R, la commande

```
glm(y ~ x1 + x2, family = binomial, data = base)
```

avec une variable réponse binaire $Y \in \{0, 1\}$ estime les paramètres :

- A) par moindres carrés ordinaires
- B) par minimisation de la somme des résidus absolus
- C) par la méthode des moments uniquement
- D) par maximum de vraisemblance
- E) aucune des réponses proposées

262. On estime une régression logistique

$$\log\left(\frac{p}{1-p}\right) = -3 + 0.04 \text{ age}.$$

Une hausse de 10 ans de l'âge multiplie les odds par environ :

- A) $\exp(0.04)$
- B) 0.4
- C) $\exp(0.4)$
- D) $10 \exp(0.04)$
- E) aucune des réponses proposées

263. Si une probabilité vaut $p = 0.8$, alors le logit de p vaut :

- A) 0.8
- B) $\log(4) \simeq 1.386$
- C) 4
- D) -1.386
- E) aucune des réponses proposées

264. Dans une régression logistique, on classe une observation en classe 1 si $\hat{p} > 0.2$. Cette règle est équivalente à :

- A) $\hat{\eta} > 0$, où $\hat{\eta}$ est le prédicteur linéaire
- B) $\hat{\eta} > 0.2$
- C) $\hat{\eta} > \log(0.2)$
- D) $\hat{\eta} > \log(0.2/0.8)$
- E) aucune des réponses proposées

265. Pour des données binomiales groupées, on peut écrire dans R :

`glm(cbind(succes, echec) ~ x, family = binomial).`

Ici, la première colonne de `cbind` représente :

- A) les probabilités estimées
- B) les résidus du modèle
- C) le nombre de succès
- D) le nombre total d'observations uniquement
- E) aucune des réponses proposées

266. Si Y_i est le nombre de succès parmi m_i essais, et si

$$Y_i | X_i \sim \text{Binomial}(m_i, p_i),$$

alors la variance de la proportion Y_i/m_i conditionnellement à X_i est :

- A) p_i

- B) $m_i p_i (1 - p_i)$
- C) $p_i (1 - p_i)$
- D) $p_i (1 - p_i) / m_i$
- E) aucune des réponses proposées

267. Dans un modèle de Poisson avec lien logarithmique, un coefficient estimé vaut $\hat{\beta} = -0.7$. Une hausse d'une unité de la variable associée :

- A) soustrait 0.7 à l'espérance
- B) multiplie l'espérance par $\exp(-0.7)$
- C) divise nécessairement l'espérance par 0.7
- D) rend l'espérance négative
- E) aucune des réponses proposées

268. Dans un modèle de Poisson pour un nombre de sinistres N_i , l'utilisation de

$$\log(E_i)$$

comme offset signifie que son coefficient est :

- A) fixé à 1
- B) estimé librement
- C) fixé à 0
- D) toujours égal à la constante du modèle
- E) aucune des réponses proposées

269. Au lieu d'utiliser un offset, on estime

$$\log(\mu_i) = \beta_0 + \alpha \log(E_i) + \beta_1 X_i.$$

Le modèle avec offset correspond au cas :

- A) $\alpha = 1$
- B) $\alpha = 0$
- C) $\alpha = \beta_1$
- D) $\alpha = -1$
- E) aucune des réponses proposées

270. Dans un GLM Gamma avec lien logarithmique,

$$\log(\mathbb{E}[Y|X]) = \beta_0 + \beta_1 X.$$

Si $\hat{\beta}_1 = 0.1$, alors une hausse d'une unité de X :

- A) augmente l'espérance de 0.1
- B) augmente l'espérance de 10 unités
- C) multiplie l'espérance par $\exp(0.1)$
- D) diminue toujours l'espérance
- E) aucune des réponses proposées

271. Dans un GLM Gamma standard, la variance conditionnelle est généralement modélisée comme proportionnelle à :

- A) μ
- B) μ^2

- C) $\sqrt{\mu}$
- D) $1/\mu$
- E) aucune des réponses proposées

272. On compare deux modèles logistiques emboîtés. Le modèle réduit a une déviance résiduelle de 210, le modèle complet une déviance résiduelle de 185. Le modèle complet ajoute deux paramètres. La statistique du test du rapport de vraisemblance vaut :

- A) 2
- B) 12.5
- C) 25
- D) 395
- E) aucune des réponses proposées

273. Pour un modèle estimé par maximum de vraisemblance, l'AIC est défini par :

- A) $-2 \log L + 2k$, où k est le nombre de paramètres
- B) R^2/k
- C) $\log L - 2k$
- D) $2 \log L + k$
- E) aucune des réponses proposées

274. Par rapport à l'AIC, le BIC :

- A) ne pénalise jamais la complexité
- B) est toujours égal à l'AIC
- C) pénalise la complexité par un terme en $k \log(n)$
- D) ne dépend pas du nombre d'observations
- E) aucune des réponses proposées

275. Pour un objet `glm` dans R, la commande

`predict(reg, type = "response")`

retourne généralement :

- A) le prédicteur linéaire $\hat{\eta}_i$
- B) la prédiction sur l'échelle de la réponse, par exemple $\hat{p}_i$ pour un modèle logistique
- C) uniquement les résidus
- D) uniquement les erreurs standards
- E) aucune des réponses proposées

276. Pour construire un intervalle de confiance sur une probabilité prédite dans un modèle logistique, une méthode courante consiste à :

- A) construire l'intervalle directement sur les résidus
- B) utiliser uniquement le R^2
- C) construire un intervalle sur l'échelle de la réponse puis appliquer le logit
- D) construire un intervalle sur l'échelle du lien puis appliquer la fonction logistique inverse
- E) aucune des réponses proposées

277. Dans un problème de classification binaire, si l'on augmente le seuil de classification de 0.5 à 0.8, alors, en général :

- A) la sensibilité augmente et la spécificité diminue

- B) la sensibilité diminue et la spécificité augmente
- C) la sensibilité et la spécificité restent toujours inchangées
- D) l'AUC devient nécessairement égale à 1
- E) aucune des réponses proposées

278. Une AUC proche de 0.5 signifie généralement que le score :

- A) classe parfaitement les observations
- B) est inutilisable car toutes les probabilités sont négatives
- C) discrimine peu mieux qu'un classement aléatoire
- D) garantit une excellente calibration
- E) aucune des réponses proposées

279. Dans un modèle quasi-Poisson, on estime un paramètre de dispersion ϕ . Si la statistique de Pearson vaut 75 pour 50 degrés de liberté, une estimation naturelle de ϕ est :

- A) 0.67
- B) 1
- C) 1.5
- D) 125
- E) aucune des réponses proposées

280. Si l'on ajuste un modèle de Poisson alors qu'il y a une forte surdispersion non prise en compte, les erreurs standards usuelles sont souvent :

- A) trop petites, ce qui peut rendre les tests trop optimistes
- B) exactement correctes
- C) toujours infinies
- D) toujours nulles
- E) aucune des réponses proposées

281. Dans une régression logistique, un coefficient $\hat{\beta} = 0.7$ signifie que, toutes choses égales par ailleurs :

- A) la probabilité est multipliée par 0.7.
- B) la probabilité augmente de 70 points de pourcentage.
- C) les *odds* sont multipliées par $\exp(0.7)$.
- D) les *odds* diminuent de 70%.
- E) Aucune des réponses proposées.

282. Dans un modèle logistique, si le prédicteur linéaire vaut

$$\eta = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 = 0,$$

quelle est la valeur prédite de $\mathbb{P}[Y = 1 \mid x_1, x_2]$?

- A) 0.25.
- B) 0.5.
- C) 0.75.
- D) 1.
- E) Aucune des réponses proposées.

283. Dans une régression de Poisson avec offset,

$$\log(\mathbb{E}[N \mid X, E]) = \log(E) + \beta_0 + \beta_1 X,$$

si $\hat{\beta}_1 = 0.3$, alors le passage de $X = 0$ à $X = 1$ multiplie le taux par environ :

- A) 0.30.
- B) 1.30.
- C) $\exp(0.3)$.
- D) $\log(0.3)$.
- E) Aucune des réponses proposées.

284. On utilise la base `Titanic`, disponible dans le package R `datasets`. On agrège les effectifs par classe, sexe et âge, puis on estime une régression logistique de la survie :

```
tt <- as.data.frame(Titanic)
wide <- reshape(tt, idvar = c("Class", "Sex", "Age"),
                 timevar = "Survived", direction = "wide")
names(wide)[names(wide) == "Freq.No"] <- "No"
names(wide)[names(wide) == "Freq.Yes"] <- "Yes"
wide <- subset(wide, Yes + No > 0)

reg_logit <- glm(cbind(Yes, No) ~ Class + Sex + Age,
                 family = binomial, data = wide)
summary(reg_logit)
```

La sortie est partiellement donnée ci-dessous :

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   0.6853     0.2730   2.510   0.0121 *
Class2nd      -1.0181     0.1960  -5.194   2.1e-07 ***
Class3rd      -1.7778     0.1716 -10.362   < 2e-16 ***
ClassCrew     -0.8577     0.1573  -5.451   5.0e-08 ***
SexFemale      2.4201     0.1404  17.236   < 2e-16 ***
AgeAdult      -1.0615     0.2440  -4.350   1.4e-05 ***

Null deviance: 671.96  on 2199  degrees of freedom
Residual deviance: 112.57  on 2195  degrees of freedom
AIC: 1560.09
```

Dans ce modèle, quelle est la catégorie de référence pour `Sex` ?

- A) Female.
- B) Male.
- C) Child.
- D) Adult.
- E) Aucune des réponses proposées.

285. Dans la sortie précédente, le coefficient de `SexFemale` vaut 2.4201. Toutes choses égales par ailleurs, les *odds* de survie des femmes sont environ :

- A) divisées par 2.42 par rapport aux hommes.
- B) multipliées par 2.42 par rapport aux hommes.
- C) multipliées par $\exp(2.4201)$ par rapport aux hommes.
- D) augmentées de 2.4201 points de probabilité.
- E) Aucune des réponses proposées.

286. D'après la sortie précédente, au seuil de 5%, quelle affirmation est correcte ?

- A) La variable `AgeAdult` n'est pas significative.
- B) La variable `SexFemale` n'est pas significative.

- C) Toutes les modalités affichées ont une p -value inférieure à 5%.
- D) Le modèle logistique ne peut pas être estimé avec des données agrégées.
- E) Aucune des réponses proposées.

287. Dans le modèle logistique estimé sur **Titanic**, la valeur prédite pour un homme adulte de troisième classe est environ :

$$\hat{\eta} = 0.6853 - 1.7778 - 1.0615 = -2.1540.$$

La probabilité prédite de survie est donc environ :

- A) -2.1540 .
 - B) 0.104 .
 - C) 0.500 .
 - D) 0.896 .
 - E) Aucune des réponses proposées.
- 288.** On compare la déviance nulle et la déviance résiduelle du modèle logistique précédent. La baisse de déviance est environ :
- A) $671.96 - 112.57$.
 - B) $112.57 - 671.96$.
 - C) $2199 - 2195$.
 - D) $1560.09 - 112.57$.
 - E) Aucune des réponses proposées.

289. On estime maintenant un modèle de Poisson sur les effectifs du tableau **Titanic** :

```
pois <- glm(Freq ~ Class + Sex + Age + Survived,
            family = poisson, data = as.data.frame(Titanic))
summary(pois)
```

Sortie partielle :

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   2.1482     0.1102  19.499 < 2e-16 ***
Class2nd      -0.1313     0.0812  -1.618  0.106
Class3rd       0.7758     0.0670  11.573 < 2e-16 ***
ClassCrew      1.0018     0.0649  15.445 < 2e-16 ***
SexFemale     -1.3037     0.0520 -25.065 < 2e-16 ***
AgeAdult       2.9545     0.0982  30.073 < 2e-16 ***
SurvivedYes   -0.7399     0.0456 -16.232 < 2e-16 ***

Null deviance: 4953.14 on 31 degrees of freedom
Residual deviance: 1243.66 on 25 degrees of freedom
```

Dans ce modèle de Poisson, le coefficient de **SurvivedYes** signifie que, toutes choses égales par ailleurs, l'espérance du nombre d'observations dans une cellule avec **Survived=Yes** est multipliée par :

- A) -0.7399 .
- B) $\exp(-0.7399)$.
- C) $1 - 0.7399$.
- D) $\log(-0.7399)$.
- E) Aucune des réponses proposées.

290. Dans la sortie du modèle de Poisson précédent, le rapport

$$\frac{\text{Residual deviance}}{\text{degrees of freedom}} = \frac{1243.66}{25}$$

est environ égal à :

- A) 0.05.
- B) 1.00.
- C) 4.97.
- D) 49.75.
- E) Aucune des réponses proposées.

291. Une valeur très élevée du rapport déviance résiduelle/degrés de liberté dans un modèle de Poisson suggère souvent :

- A) une sous-dispersion ou un ajustement parfait.
- B) une surdispersion ou un manque d'ajustement du modèle.
- C) que tous les coefficients sont nécessairement nuls.
- D) que la fonction de lien logit a été utilisée par erreur.
- E) Aucune des réponses proposées.

292. Dans un GLM, on écrit généralement

$$g(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

La quantité η_i est appelée :

- A) la déviance
- B) le prédicteur linéaire
- C) la variance conditionnelle
- D) le résidu de Pearson
- E) aucune des réponses proposées

293. Dans un GLM, la fonction de lien g relie :

- A) la variance conditionnelle à la déviance
- B) la réponse observée directement aux résidus
- C) l'espérance conditionnelle $\mu_i = \mathbb{E}[Y_i \mid \mathbf{x}_i]$ au prédicteur linéaire
- D) l'AIC au nombre d'observations
- E) aucune des réponses proposées

294. Dans une régression logistique, si

$$\eta_i = \log\left(\frac{p_i}{1 - p_i}\right) = 1.2,$$

alors les odds valent :

- A) 1.2
- B) $\exp(1.2)$
- C) $1/(1 + \exp(-1.2))$
- D) $\log(1.2)$
- E) aucune des réponses proposées

295. Dans une régression logistique, si $\eta_i = 1.2$, alors la probabilité prédite vaut environ :

- A) 0.23
- B) 0.50
- C) 0.77
- D) 1.20
- E) aucune des réponses proposées

296. Dans une régression logistique, un coefficient estimé $\hat{\beta} = -0.5$ signifie que, toutes choses égales par ailleurs, une hausse d'une unité de la variable associée :

- A) diminue les odds d'un facteur $\exp(-0.5)$
- B) diminue toujours la probabilité de 0.5
- C) augmente les odds de 0.5
- D) rend la probabilité négative
- E) aucune des réponses proposées

297. Dans une régression logistique, si la probabilité prédite vaut $p = 0.25$, alors le logit vaut :

- A) $\log(0.25)$
- B) $\log(0.25/0.75)$
- C) $0.25/0.75$
- D) $1/(1 + \exp(-0.25))$
- E) aucune des réponses proposées

298. On estime une régression logistique et on obtient la sortie suivante :

Coefficients:				
	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.2000	0.3000	-4.00	6.3e-05 ***
x	0.8000	0.2000	4.00	6.3e-05 ***

La statistique de test associée à x vaut :

- A) 0.16
- B) 0.25
- C) 4.00
- D) 6.3
- E) aucune des réponses proposées

299. Dans la sortie précédente, la probabilité prédite pour $x = 0$ vaut environ :

- A) 0.23
- B) 0.50
- C) 0.77
- D) 1.20
- E) aucune des réponses proposées

300. Dans la sortie précédente, la probabilité prédite pour $x = 2$ vaut environ :

- A) 0.40
- B) 0.60
- C) 0.88
- D) 1.60
- E) aucune des réponses proposées

301. Dans un modèle logistique, si l'on augmente le seuil de classification de 0.5 à 0.7, alors en général :

- A) on classe plus d'observations en classe 1
- B) on classe moins d'observations en classe 1
- C) l'AUC augmente nécessairement
- D) les coefficients changent nécessairement
- E) aucune des réponses proposées

302. Une courbe ROC décrit :

- A) la relation entre la déviance et l'AIC
- B) les valeurs de sensibilité et de spécificité obtenues lorsque le seuil de classification varie
- C) uniquement les résidus du modèle
- D) uniquement les coefficients estimés
- E) aucune des réponses proposées

303. Une AUC proche de 1 indique généralement :

- A) une très bonne capacité de discrimination
- B) une absence totale de discrimination
- C) une calibration parfaite
- D) une variance résiduelle négative
- E) aucune des réponses proposées

304. Dans une régression de Poisson avec lien logarithmique,

$$\log(\mu_i) = \beta_0 + \beta_1 x_i.$$

Si $\hat{\beta}_1 = 0.4$, alors une hausse d'une unité de x multiplie μ_i par :

- A) 0.4
- B) 1.4
- C) $\exp(0.4)$
- D) $\log(0.4)$
- E) aucune des réponses proposées

305. Dans un modèle de Poisson standard, on suppose :

- A) $\text{Var}(Y_i | \mathbf{x}_i) = \mu_i$
- B) $\text{Var}(Y_i | \mathbf{x}_i) = \mu_i^2$
- C) $\text{Var}(Y_i | \mathbf{x}_i) = 1$
- D) $\text{Var}(Y_i | \mathbf{x}_i) = 0$
- E) aucune des réponses proposées

306. Dans une régression de Poisson avec offset,

$$\log(\mu_i) = \log(e_i) + \beta_0 + \beta_1 x_i.$$

Le terme $\log(e_i)$ a un coefficient :

- A) estimé librement
- B) fixé à 1
- C) fixé à 0

- D) égal à β_1
- E) aucune des réponses proposées

307. Dans le modèle précédent, si l'exposition e_i double, à x_i fixé, alors μ_i :

- A) reste inchangée
- B) double
- C) est divisée par deux
- D) augmente de β_1
- E) aucune des réponses proposées

308. On estime un modèle de Poisson et on obtient :

Residual deviance: 180.0 on 60 degrees of freedom

Le rapport déviance résiduelle/degrés de liberté vaut :

- A) 0.33
- B) 1.00
- C) 3.00
- D) 60.00
- E) aucune des réponses proposées

309. Une valeur élevée du rapport déviance résiduelle/degrés de liberté dans un modèle de Poisson suggère souvent :

- A) une possible surdispersion
- B) une sous-dispersion parfaite
- C) que tous les coefficients sont nuls
- D) que la fonction de lien est nécessairement identité
- E) aucune des réponses proposées

310. En présence de surdispersion dans un modèle de Poisson, une solution possible est :

- A) utiliser un modèle quasi-Poisson ou binomial négatif
- B) supprimer la constante
- C) transformer toutes les réponses en variables binaires
- D) imposer que tous les coefficients soient nuls
- E) aucune des réponses proposées

311. Dans un modèle quasi-Poisson, on permet généralement :

- A) $\text{Var}(Y_i | \mathbf{x}_i) = \phi \mu_i$
- B) $\text{Var}(Y_i | \mathbf{x}_i) = 0$
- C) $\mu_i < 0$
- D) une fonction de lien toujours logit
- E) aucune des réponses proposées

312. On compare deux GLM emboîtés. Le modèle réduit a une déviance résiduelle de 250, et le modèle complet une déviance résiduelle de 230. Le modèle complet ajoute 2 paramètres. La statistique du test du rapport de vraisemblance vaut :

- A) 2
- B) 10

- C) 20
- D) 480
- E) aucune des réponses proposées

313. Dans un GLM estimé par maximum de vraisemblance, l'AIC est :

- A) $-2 \log L + 2k$
- B) $\log L/k$
- C) $R^2 + 2k$
- D) la déviance divisée par le nombre d'observations
- E) aucune des réponses proposées

314. Entre deux modèles estimés sur les mêmes données, selon le critère AIC, on préfère généralement :

- A) le modèle ayant l'AIC le plus faible
- B) le modèle ayant l'AIC le plus élevé
- C) le modèle ayant toujours le plus grand nombre de variables
- D) le modèle ayant toujours le plus petit nombre d'observations
- E) aucune des réponses proposées

315. Dans un GLM Gamma avec lien logarithmique,

$$\log(\mu_i) = \beta_0 + \beta_1 x_i.$$

Si $\hat{\beta}_1 = 0.2$, une hausse d'une unité de x multiplie μ_i par :

- A) 0.2
- B) 1.2
- C) $\exp(0.2)$
- D) $\log(0.2)$
- E) aucune des réponses proposées

316. Dans un GLM Gamma standard, la variance conditionnelle est proportionnelle à :

- A) μ_i
- B) μ_i^2
- C) $\sqrt{\mu_i}$
- D) $1/\mu_i$
- E) aucune des réponses proposées

317. Un modèle Gamma est surtout adapté à une réponse :

- A) binaire
- B) de comptage avec beaucoup de zéros uniquement
- C) continue, strictement positive, souvent asymétrique
- D) qualitative nominale
- E) aucune des réponses proposées

318. Le modèle binomial négatif est souvent utilisé comme alternative au modèle de Poisson lorsque :

- A) il y a surdispersion dans les données de comptage
- B) la réponse est strictement binaire
- C) toutes les observations sont négatives

- D) la variance est nécessairement nulle
- E) aucune des réponses proposées

319. Dans un GLM, les résidus de Pearson servent notamment à :

- A) comparer l'observation à sa moyenne prédite en tenant compte de la variance modélisée
- B) calculer directement les coefficients par moindres carrés ordinaires
- C) imposer que la réponse soit normale
- D) remplacer la fonction de lien
- E) aucune des réponses proposées

320. Dans un modèle Tweedie, on utilise souvent la fonction de variance :

$$\text{Var}(Y_i | \mathbf{x}_i) = \phi \mu_i^p.$$

Le paramètre p contrôle :

- A) uniquement la constante du modèle
- B) la forme de la relation moyenne-variance
- C) uniquement le nombre d'observations
- D) le seuil de classification
- E) aucune des réponses proposées

321. Dans la famille Tweedie, le cas $p = 1$ correspond à :

- A) une variance proportionnelle à μ_i , comme dans le modèle de Poisson
- B) une variance proportionnelle à μ_i^2 , comme dans le modèle Gamma
- C) une variance constante, comme dans le modèle normal
- D) une variance nulle
- E) aucune des réponses proposées

322. Dans la famille Tweedie, le cas $p = 2$ correspond à :

- A) une variance proportionnelle à μ_i
- B) une variance proportionnelle à μ_i^2 , comme dans le modèle Gamma
- C) une variance constante
- D) une loi Bernoulli
- E) aucune des réponses proposées

323. Pour $1 < p < 2$, un modèle Tweedie est souvent utilisé pour modéliser :

- A) une variable binaire sans valeurs positives continues
- B) une variable continue strictement négative
- C) une variable avec une masse en zéro et des valeurs positives continues
- D) une variable qualitative à plusieurs modalités
- E) aucune des réponses proposées

324. En assurance, le modèle Tweedie avec $1 < p < 2$ est utile pour modéliser directement :

- A) le coût agrégé de sinistres, avec beaucoup de zéros et des montants positifs lorsqu'il y a sinistre
- B) uniquement le nombre de sinistres, sans montants
- C) uniquement la probabilité d'avoir un sinistre
- D) uniquement une variable explicative qualitative

E) aucune des réponses proposées

325. Dans un modèle Tweedie avec lien logarithmique,

$$\log(\mu_i) = \beta_0 + \beta_1 x_i.$$

Si $\hat{\beta}_1 = 0.3$, alors une hausse d'une unité de x multiplie l'espérance μ_i par :

- A) 0.3
- B) 1.3
- C) $\exp(0.3)$
- D) $\log(0.3)$
- E) aucune des réponses proposées

326. Dans R, un modèle Tweedie peut être estimé, par exemple, avec une syntaxe du type :

```
glm(y ~ x1 + x2, family = tweedie(var.power = p,  
                                   link.power = 0),  
     data = base)
```

Ici, `link.power = 0` correspond généralement :

- A) au lien identité
- B) au lien logarithmique
- C) au lien logit
- D) à l'absence de variable explicative
- E) aucune des réponses proposées

327. Dans un modèle Tweedie avec $1 < p < 2$, la présence de valeurs exactement nulles dans la réponse :

- A) rend toujours le modèle impossible
- B) est compatible avec le modèle
- C) impose une régression logistique
- D) impose une loi normale
- E) aucune des réponses proposées

328. On estime un modèle Tweedie avec lien logarithmique :

$$\log(\mu_i) = 2 + 0.4x_i.$$

Pour $x_i = 0$, la moyenne prédite vaut :

- A) 2
- B) $\exp(2)$
- C) 0.4
- D) $\exp(0.4)$
- E) aucune des réponses proposées

329. Dans le modèle précédent, le passage de $x = 0$ à $x = 1$ multiplie la moyenne prédite par :

- A) 0.4
- B) 1.4
- C) $\exp(0.4)$
- D) $\exp(2)$

E) aucune des réponses proposées

330. Un avantage du modèle Tweedie pour une prime pure est qu'il peut, dans un seul modèle :

A) combiner la fréquence et la sévérité via une espérance de coût agrégé

B) supprimer automatiquement tous les sinistres

C) transformer toutes les réponses en variables binaires

D) garantir que tous les coefficients sont positifs

E) aucune des réponses proposées

Réponses

Question	1	2	3	4	5	6	7	8	9	10
Réponse	B	A	C	C	B	B	A	D	C	B
Question	11	12	13	14	15	16	17	18	19	20
Réponse	C	D	B	A	A	B	C	A	C	B
Question	21	22	23	24	25	26	27	28	29	30
Réponse	B	B	C	C	B	A	C	B	C	D
Question	31	32	33	34	35	36	37	38	39	40
Réponse	B	C	A	C	B	A	D	C	B	C
Question	41	42	43	44	45	46	47	48	49	50
Réponse	B	B	C	B	A	C	A	B	C	A
Question	51	52	53	54	55	56	57	58	59	60
Réponse	A	C	D	B	B	B	B	A	C	A
Question	61	62	63	64	65	66	67	68	69	70
Réponse	B	C	C	A	B	B	C	B	B	D
Question	71	72	73	74	75	76	77	78	79	80
Réponse	C	D	B	C	C	B	A	C	D	C
Question	81	82	83	84	85	86	87	88	89	90
Réponse	B	D	A	B	C	A	D	C	B	D
Question	91	92	93	94	95	96	97	98	99	100
Réponse	B	B	C	C	A	C	B	B	C	C
Question	101	102	103	104	105	106	107	108	109	110
Réponse	B	B	C	C	D	A	C	B	C	C
Question	111	112	113	114	115	116	117	118	119	120
Réponse	B	B	B	C	D	A	C	B	B	A
Question	121	122	123	124	125	126	127	128	129	130
Réponse	A	C	A	C	A	C	B	D	A	D
Question	131	132	133	134	135	136	137	138	139	140
Réponse	B	C	B	B	A	C	D	C	C	A
Question	141	142	143	144	145	146	147	148	149	150
Réponse	C	B	B	A	B	B	C	A	C	B
Question	151	152	153	154	155	156	157	158	159	160
Réponse	B	B	C	A	D	B	A	B	A	C
Question	161	162	163	164	165	166	167	168	169	170
Réponse	C	A	C	A	D	C	C	B	C	A
Question	171	172	173	174	175	176	177	178	179	180
Réponse	B	B	B	B	A	C	B	A	B	C
Question	181	182	183	184	185	186	187	188	189	190
Réponse	B	A	C	B	D	C	B	B	C	B
Question	191	192	193	194	195	196	197	198	199	200
Réponse	A	D	C	D	C	A	B	A	B	B
Question	201	202	203	204	205	206	207	208	209	210
Réponse	D	B	C	B	C	A	D	A	B	D
Question	211	212	213	214	215	216	217	218	219	220
Réponse	C	A	B	A	D	B	C	A	D	C

Question	221	222	223	224	225	226	227	228	229	230
Réponse	B	D	C	B	D	D	A	B	C	B
Question	231	232	233	234	235	236	237	238	239	240
Réponse	C	C	B	C	B	D	A	C	B	C
Question	241	242	243	244	245	246	247	248	249	250
Réponse	B	C	B	C	D	C	B	B	C	B
Question	251	252	253	254	255	256	257	258	259	260
Réponse	B	C	D	C	A	C	C	C	A	C
Question	261	262	263	264	265	266	267	268	269	270
Réponse	D	C	B	D	C	D	B	A	A	C
Question	271	272	273	274	275	276	277	278	279	280
Réponse	B	C	A	C	B	D	B	C	C	A
Question	281	282	283	284	285	286	287	288	289	290
Réponse	C	B	C	B	C	C	B	A	B	D
Question	291	292	293	294	295	296	297	298	299	300
Réponse	B	B	C	B	C	A	B	C	A	B
Question	301	302	303	304	305	306	307	308	309	310
Réponse	B	B	A	C	A	B	B	C	A	A
Question	311	312	313	314	315	316	317	318	319	320
Réponse	A	C	A	A	C	B	C	A	A	B
Question	321	322	323	324	325	326	327	328	329	330
Réponse	A	B	C	A	C	B	B	C	A	A